

머신러닝 기초

모델 평가의 핵심 개념 — 왜 정확도만으로는 안 되는가

교육용 강의 노트

1. 모델링과 피팅(Fitting).....	2
1-1. 과소적합 · 적정적합 · 과대적합	2
2. 파라미터 vs 하이퍼파라미터.....	3
3. 혼동행렬(Confusion Matrix) 해석	4
4. 평가지표 — 정확도, 재현율, F1, AUC	5
4-1. [중요] 왜 정확도(Accuracy)는 중요하지 않은가?	5
4-2. F1 과 AUC 를 언제 쓰나.....	6
5. 위양성 줄이기 — 1 종 오류와 2 종 오류.....	7
5-1. 위양성(헛경보)을 줄이는 실무 방법	7
부록. 한 장 요약.....	9

1. 모델링과 피팅(Fitting)

$$y = ax + b$$


머신러닝에서 **모델링(Modeling)**은 데이터 속에 숨은 규칙을 수학적 함수로 표현하는 작업이고, **피팅(Fitting, 학습/적합)**은 그 함수의 내부 값들을 데이터에 맞게 조정해 가는 과정이다. 즉 "빈 틀(모델)"을 준비하고, 데이터를 보여주며 "틀을 데이터에 맞춰 깎는" 것이 피팅이다.

적합한 값 찾기

- 입력(X) → 모델 $f(X)$ → 예측($\hat{y}$)의 구조에서, 예측이 정답(y)에 가까워지도록 내부 값을 갱신한다.
- 이때 "얼마나 틀렸는가"를 재는 자가 손실 함수(Loss)이고, 손실을 줄이는 방향으로 값을 미는 것이 학습이다.

PoC = proof of concept

피팅 찾기



1-1. 과소적합 · 적정적합 · 과대적합

피팅의 결과는 세 가지로 갈린다. 핵심은 "학습 데이터"가 아니라 "처음 보는 데이터"에서의 성능이다.

Train / Test

- **과소적합(Underfitting)**: 모델이 너무 단순해 규칙조차 못 배운 상태. 학습·검증 성능이 모두 낮다.
- **적정적합(Good fit)**: 규칙은 잡고 잡음(noise)은 무시. 검증 데이터에서도 잘 맞는 이상적 상태.
- **과대적합(Overfitting)**: 학습 데이터를 통째로 외워버림. 학습 성능은 거의 100%인데 새 데이터에선 급락한다.

핵심 직관 — 편향-분산 트레이드오프

- 편향(Bias)이 크면 = 과소적합: 너무 뭉뚱그려 본다.
- 분산(Variance)이 크면 = 과대적합: 잡음까지 따라가 흔들린다.
- 좋은 모델은 둘 사이의 균형점. 그래서 "학습 점수"가 아니라 "검증 점수"로 멈출 시점을 정한다.

오버피팅 줄이는 방법

1. training을 validation에 비교한 뒤 test
2. regularization : 뒤에 항을 붙여서 차수를 뺌

2. 파라미터 vs 하이퍼파라미터

이름은 비슷하지만 "누가 정하느냐"가 완전히 다르다. 이 구분이 학습 과정 전체의 뼈대다.

	파라미터 (Parameter)	하이퍼파라미터 (Hyperparameter)
누가 정하나	모델이 학습으로 스스로 찾음	사람이 학습 전에 미리 설정
언제 정해지나	학습(피팅) 도중 갱신	학습 시작 전 고정
예시	회귀계수(가중치 w), <u>절편 b</u> , 신경망 weight	<u>학습률</u> , <u>에폭 수</u> , <u>트리 깊이</u> , K 값, 규제 강도
비유	요리 중 손이 익혀 잡는 "간"	요리 전에 맞춰두는 "오븐 온도·시간"

하이퍼파라미터 튜닝이란 이 "사람이 정하는 값"들의 좋은 조합을 찾는 일이다. 그리드 서치, 랜덤 서치, 베이지안 최적화 등이 쓰이며, 반드시 검증(validation) 데이터로 평가해야 한다. 테스트 데이터로 튜닝하면 점수를 속이게 된다.

베이지안 ?

3. 혼동행렬(Confusion Matrix) 해석

모든 분류 평가지표는 결국 이 2×2 표 한 장에서 나온다. 여기를 못 읽으면
정확도·정밀도·재현율을 외워도 무용지물이다. *total: 100*

	예측: 양성(P)	예측: 음성(N)
실제: 양성(P)	TP 50 True Positive 맞게 잡은 양성	FN 5 False Negative 놓친 양성 · 2종 오류
실제: 음성(N)	FP 5 False Positive 헛경보 · 1종 오류	TN 40 True Negative 맞게 거른 음성

읽는 법은 항상 "뒤 글자(P/N) = 모델의 예측, 앞 글자(T/F) = 그 예측이 맞았는가"이다.

- **TP**: 양성이라 했고 실제로 양성 — 정답
 - **TN**: 음성이라 했고 실제로 음성 — 정답
 - **FP**: 양성이라 했는데 사실은 음성 — 위양성 / 1종 오류(헛경보) *이것을 줄이는 것이 목표 중 하나*
 - **FN**: 음성이라 했는데 사실은 양성 — 위음성 / 2종 오류(놓침)
- 이게 많은 모델은*

외우는 한 줄


"F로 시작하면 틀린 것, 뒤 글자는 모델이 뭐라고 했는지."

FP = 모델이 'P(양성)'라고 했는데 틀림(헛경보), FN = 모델이 'N(음성)'이라 했는데 틀림(놓침).

4. 평가지표 — 정확도, 재현율, F1, AUC

혼동행렬의 네 칸(TP·FP·FN·TN)을 어떻게 조합하느냐에 따라 보는 관점이 달라진다.

지표	계산식	질문 / 무엇을 보는가
정확도 Accuracy	모델 성능(일단은 이걸로) $(TP+TN) / \text{전체}$ 90%	전체 중 맞춘 비율. 클래스가 한쪽으로 쏠리면 의미가 무너진다.
정밀도 Precision	$TP / (TP+FP)$	"양성이라 한 것 중 진짜 양성?" 위양성(FP)이 비쌀 때 중요.
재현율 Recall(민감도)	실제 양성-2보전 $TP / (TP+FN)$	" <u>실제</u> 양성 중 몇 개를 잡았나?" 놓침(FN)이 치명적일 때 중요.
F1 점수	하모니 균형을 잘 맞춘다 $2 \cdot (P \cdot R) / (P+R)$	정밀도와 재현율의 조화평균. 둘의 균형을 한 숫자로.
AUC (ROC 곡선 아래 면적)	ROC 곡선 적분 (0.5~1.0)	임계값을 옮겨가며 본 종합 분별력. 0.5=무작위, 1.0=완벽.



4-1. [중요] 왜 정확도(Accuracy)는 중요하지 않은가?

정확도는 가장 먼저 배우지만, 실무에서 가장 사람을 속이는 지표다. 이유는 한 단어로 "불균형(imbalance)"이다.

암 진단 데이터에서 실제 환자가 **100 명 중 1 명(1%)**이라고 하자. 아무 학습도 하지 않고 무조건 "정상"이라고만 답하는 바보 모델을 만들면, 100 명 중 99 명을 맞히므로 정확도는 **무려 99%**가 나온다. 숫자는 화려하지만, 정작 **잡아야 할 환자는 단 한 명도 못 잡았다.**

지표	바보 모델 ("전부 정상"이라 답)	쓸모 있는 모델
정확도(Accuracy)	99.0% (높아 보임!)	98.2%
재현율(Recall, 환자 검출)	0% (한 명도 못 잡음)	90%
정밀도(Precision)	정의 불가 (양성 예측 0)	85%

이 표가 말하는 바는 분명하다. 정확도 99%짜리 모델이 정확도 98%짜리 모델보다 훨씬 위험하다. 정확도는 "다수 클래스를 잘 맞혔는지"에 끌려다니기 때문에, 정작 중요한 소수 클래스(환자, 사기, 불량) 성능을 가려버린다.

그래서 무엇을 봐야 하나

- 데이터가 불균형하면 정확도 대신 정밀도·재현율·F1 을 본다.
- 놓치면 큰일(암, 사기, 화재) → 재현율(Recall)을 우선한다.
- 헛경보가 비싸면(스팸으로 중요 메일 삭제, 멀쩡한 거래 차단) → 정밀도(Precision)를 우선한다.
- 둘의 균형을 한 숫자로 보고 싶으면 F1, 임계값과 무관한 종합 분별력을 보려면 AUC.

4-2. F1 과 AUC 를 언제 쓰나

- **F1 점수** : 정밀도와 재현율이 서로 줄다리기할 때, 한쪽만 높고 다른 쪽이 낮은 모델에 별점을 준다(조화평균이라 낮은 쪽에 끌려감). 불균형 데이터의 단일 비교 지표로 적합.
- **AUC(ROC)** : 분류 임계값(0.5 등)을 0 부터 1 까지 전부 옮겨보며 그린 곡선의 면적. 임계값을 어디에 두든 "양성을 음성보다 앞에 세우는 능력"을 하나로 요약한다. 0.5 는 동전 던지기, 1.0 은 완벽.

5. 위양성 줄이기 — 1 종 오류와 2 종 오류

통계의 가설검정 용어가 그대로 머신러닝으로 넘어온 것이다. 두 오류는 본질적으로 "트레이드오프" 관계라, 동시에 0 으로 만들 수는 없다.

구분	정체	의미	현실 예시(스팸 필터)
1 종 오류 (Type I)	위양성 (FP) 거짓 정보	아닌데 맞다고 함 (귀무가설을 잘못 기각)	정상 메일을 스팸으로 분류 → 중요한 메일을 놓침
2 종 오류 (Type II)	위음성 (FN) 놓침	맞는데 아니라고 함 (거짓 귀무가설을 못 기각)	스팸을 정상으로 통과 → 받은편지함이 더러워짐

핵심 — 둘은 시소다

임계값(threshold)을 올려 "확실할 때만 양성"이라 하면 → 위양성(FP) ↓ 정밀도 ↑, 하지만 놓침(FN) ↑ 재현율 ↓.

임계값을 내려 "의심되면 일단 양성"이라 하면 → 놓침(FN) ↓ 재현율 ↑, 하지만 위양성(FP) ↑ 정밀도 ↓.

그래서 "무엇을 더 두려워하는가"를 먼저 정하고 임계값을 옮긴다.

5-1. 위양성(헛정보)을 줄이는 실무 방법

1. **분류 임계값을 높인다** : 0.5 → 0.7 등으로 올려, 모델이 충분히 확신할 때만 양성 판정. 가장 직접적이고 즉시 효과가 있다.
2. **정밀도(Precision)를 최적화 지표로 삼는다** : 모델 선택·튜닝 기준을 정확도가 아니라 정밀도(또는 Precision 중심 F-beta)로 둔다.
3. **특징·데이터 품질을 개선한다** : 양성·음성을 가르는 변별력 있는 변수를 추가하고, 라벨 오류를 정리한다.
4. **비용 민감 학습 / 클래스 가중치** : FP 에 더 큰 페널티를 부여해 모델이 함부로 양성이라 하지 않도록 학습시킨다.

5. **PR 곡선으로 운영점을 고른다** : Precision-Recall 곡선에서 허용 가능한 재현율을 유지하는 선에서 정밀도가 가장 높은 임계값을 채택한다.

단, 공짜는 없다

위양성을 줄이려고 임계값을 높이면 거의 항상 위음성(놓침)이 늘어난다.

암 진단·사기탐지처럼 "놓치면 더 큰 손해"인 영역에서는 위양성을 일부 감수하고 재현율을 지키는 편이 옳다.

결국 정답은 도메인이 정한다 — 지표는 의사결정을 돕는 도구일 뿐, 목표 그 자체가 아니다.

부록. 한 장 요약

- 피팅 = 모델을 데이터에 맞춰 깎기. 핵심은 학습 점수가 아니라 검증 점수(과대적합 경계).
- 파라미터 = 모델이 학습으로 찾는 값 / 하이퍼파라미터 = 사람이 미리 정하는 값.
- 모든 분류 지표는 혼동행렬(TP·FP·FN·TN)에서 나온다.
- 정확도는 불균형 데이터에서 사람을 속인다 — 소수 클래스가 중요하다면 재현율·정밀도·F1·AUC 를 본다.
- 1 종 오류 = 위양성(헛경보) / 2 종 오류 = 위음성(놓침), 둘은 시소 관계.
- 위양성을 줄이려면 임계값 ↑ · 정밀도 최적화 · 비용가중 · PR 곡선 활용 — 단 놓침(FN) 증가를 각오할 것.