

2025 AI 트렌드 딥다이브

[구름 위에서 땅으로 내려온 AI(Physical AI, Agentic AI, OnDevice AI)]

신동형



(2025.04.21)

“편안하게 활용하시고 많이 공유해 주세요. 단, 인용시 반드시 출처를 밝혀 주십시오”

1. 저자 소개

N | **신동형 (申东亨)**

통합 VIEW 이미지 지식iN 인플루언서 동영상 쇼핑 뉴스 어학사전 지도 ...

신동형
기업인

전체 | 프로필 | 최근활동 | 작품활동

프로필
출생 1976. 6. 4. 대구광역시
소속 알서포트(팀장)
학력 서울대학교 대학원 경영학과 석사
수상 2007년 QUALCOMM 무선통신 연구논문 공모전 대상
경력 2017.07~ 알서포트 전략기획팀 팀장
사이트 인스타그램, 페이스북, 블로그
작품 도서, 기타



👉 네이버 인물 정보 링크([LINK](#))


- (現)알서포트 전략기획팀장
- (前)게임 소셜 미디어 게임덕 대표이사
- (前)LG경영연구원 산업부문 책임연구원
- (前) 서울대학교 경영대학 석사
- (前) 삼성전자 무선 사업부 지원 그룹

👉 신동형의 테크 지식 탐험([LINK](#))

👉 링크드인 링크([LINK](#))

해당 자료는 <변화 너머> 책을 정리한 내용으로, ‘스마트폰 너머’, ‘메타버스 너머’ 변화의 핵심이 될 XIA가 2040년까지 사람들, 그리고 사회·경제를 포함한 세상 변화에 대한 내용을 담았음.

2040년까지 세상을 지배할 기술 혁신 : XIA



3. 들어가며

① CES 보고서

최근 AI가 가장 핵심 트렌드임. 이 보고서도 AI와 함께 새로운 도전을 해 낼 수 있었음. 생산성 100배 AI인 최강 팀원들!!!


최강 AI 팀원들과 함께 만들어 낸 476page 짜리 CES 2025 최강 보고서



[LINK](#)

최근 AI가 가장 핵심 트렌드임. 이 보고서도 AI와 함께 새로운 도전을 해 낼 수 있었음. 생산성 100배 AI인 최강 팀원들!!!

최강 AI 팀원들과 함께 만들어 낸 897page 짜리 MWC 2025 최강 보고서



[LINK](#)

| 목차

이야기①

2025년 AI 트렌드

이야기②

물리적 AI(Physical AI)

이야기③

AI 에이전트(Agentic AI)

이야기④

온디바이스AI(OnDevice AI)

| 목차

이야기①

2025년 AI 트렌드

이야기②

물리적 AI(Physical AI)

이야기③

AI 에이전트(Agentic AI)

이야기④


온디바이스AI(OnDevice AI)

1. 2025년 AI 2.0 시대로 전환


① 개요

AI는 정말 빠르게 변화하고 있음. 2025년에는 AI 2.0으로 구름에서 실체있는 땅으로 내려오고 있음.

AI 1.0(LLM 기반 Gen AI로 진화)



AI 2.0(하늘에서 땅으로 내려온 AI)



2. 2025년 논의된 AI

① 젤슨 황의 CES 2025 기조 연설

NVIDIA는 3가지 AI 트렌드를 언급했음. 디지털 공간에 머무르지 않고 물리적 세상으로 나온
①물리적 AI, 행동 가능한 ②에이전틱AI, NPU 중심의 AI PC가 아닌③GPU 중심인 PSC임.

물리적 AI(Physical AI)

- 코스모스 플랫폼
 - 물리적 세계를 이해하고 예측하기 위한 물리적 기반 모델임.
 - 중력, 마찰, 관성과 같은 물리적 역학과 기하학적, 공간적 관계를 이해하고 원인과 결과를 파악할 수 있는 능력 有
- 3중 솔루션의 구현
 - DGX 시스템이 기본 AI 모델의 학습 담당
 - Omniverse와 Cosmos 결합으로 시뮬레이션과 강화학습을 담당함. 즉 디지털 트윈을 생성하고 학습함.
 - AGX는 실제 환경에서의 추론을 담당함. 로봇이나 자율주행차량에 탑재되어

에이전틱 AI(Agentic AI)

- 지식 로봇 에이전틱AI
 - 단순 챗봇을 넘어 추론하고, 계획을 세우고, 행동가능한 지식로봇으로 진화
 - 특히, 전 세계 설치된 15억대 기업용 카메라들이 매년 생성하는 7조 시간의 영상 데이터 중 실시간으로 사람이 모니터링하는 비율이 1%에 불과
- AI Blueprint 제공
 - 기업의 업무 자동화를 위한 AI 에이전트 구축 및 배포를 위한 프레임워크
 - AI 서비스 개발용 기능 모음 플랫폼인 NVIDIA NIM 마이크로 서비스와 AI 모델 개발을 위한 프레임워크인 NVIDIA NeMO포함함.

PC → PSC(개인용슈퍼컴퓨터) 시대

- 새로운 Blackwell 아키텍처 기반의 RTX 50 시리즈 출시
 - RTX, NVIDIA 그래픽 카드 브랜드로 제조사들이 이를 기반으로 그래픽 카드 개발·제조
 - 게이머, 전문 크리에이터, 개발자 등이 개인용으로 활용
- 윈도우에서 CUDA가 지원하는 리눅스 기반 AI 컴퓨팅 활용 가능
 - WSL2(Window Subsystem for Linux2)
- 개인용 슈퍼 컴퓨터 Project DIGITS 발표
 - GB110 칩 기반으로 \$3,000 예상

※ Source : NVIDIA CEO Jensen Huang Keynote at CES 2025 (Youtube, 2025)([LINK](#)), NVIDIA and Partners Launch Agentic AI Blueprints to Automate Work for Every Enterprise (Boitano Justin, 2025)([LINK](#)), NVIDIA Announces Isaac GR00T Blueprint to Accelerate Humanoid Robotics Development (Huangpencer, 2025)([LINK](#)), NVIDIA CES 2025 Keynote Live Coverage(SmithRyan, 2025)([LINK](#))

3. 액센추어, 기업들의 AI 도입시 고려 사항

① 개요

엑센추어에서는 AI 시대 기업들에게 3가지를 조언함. ①전사적으로 통합된 AI 도입 및 활용 필요, ②AI는 기술적·감정적 신뢰가 필수, ③물리적 AI에 대한 준비 필요함.

AI, 전사적 구조화된 두뇌 도입으로

● AI 도입 현 주소

구분	AS-IS	TO-BE
접근방식	부서별 개별 도입	전사적 구조화
데이터 활용	단편적 접근	통합적 활용
인증 프로세스	부재	표준화된 인증
도입 효과	제한적	전사적 시너지

● 회사에 「AI 두뇌」 적용 후 마케팅부서

프로세스	도입 전	도입 후
시장 조사	수일~수주 소요	수분 내 완료
경쟁사 분석	수동 비교 분석	실시간 차별화
품질 검토	다단계 인적 검토	AI 실시간 피드백
총 소요 시간	수주	약 50% 단축

AI, 신뢰가 필수

- Sweet 회장은 AI 도입을 위해서는 2가지 신뢰와 플러스 1가 필요함.
- 기술적 신뢰(“이거 정말 될까?”)
 - AI가 작동한다는 것을 보여주→ 실제 업무 환경에서 가치 창출 확인
- 감정적 신뢰(“내 자리는 괜찮을까?”)
 - 가장 많이 듣는 질문이 “우리 아이들은 어떤 공부를 해야 할까요?”는 일자리에 대한 불안감이라 인식
- AI와 함께 일하는 방법 배우기
 - 단순 기술 도입을 넘어 조직 문화 전환을 위해 “변화의 용기”와 “구성원과 함께 하는 여정”에 대한 리더십 필요함.

Physical AI

- Accenture는 NVIDIA, Kion Group과 협력하여 물류창고 솔루션 개발
 - 디지털 트윈을 통해서 본질적으로 인간 근로자와 기계가 원활하고 안전하게 협업하도록 환경 조성할 것임.
 - ① 구성 시뮬레이션 및 테스트: 테스트를 위해서 작업을 중단하지 않고 진행
 - ②창고 로봇이 수요, 재고 변동 및 레이아웃 변경과 같은 변화 조건을 최상의 방식으로 처리 등 최적화
 - ③병목 현상, 사고 및 기타 예상치 못한 이벤트의 위험을 줄임.

※ Source : CES 2025 Keynote with Accenture Chair and CEO, Julie Sweet (CES, 2025)([LINK](#))

③ Julie Sweet이 생각하는 AI 시대 일하는 방식

AI 시대에 AI로 인한 업무 대체는 불가피함. ①반복적 업무→창의적 전략, ②후대응 →예측적 관리, ③기본 데이터 분석 → 통합적 데이터 관리를 통한 전략적 인사이드 도출 3가지임. 뿐만 아니라 전사 직원들의 AI 스킬 함양을 위해 연간 약 11억 달러의 비용을 투자하고 있음.

AI 시대 새로운 업무 예시

기존 업무	새로운 업무	핵심 변화
반복적 콘텐츠 제작	하이퍼 개인화 마케팅	창의적 전략 수립
수동 품질 관리	AI 기반 품질 최적화	예측적 관리
기본 데이터 분석	통합 데이터 전략 수립	전략적 인사이드 도출

액센추어에서 어떻게

- AI로 인한 업무 대체는 불가피함.
 - 이는 단순한 인력 감축이 아닌 업무 혁신의 기회임.
 - 실제로 '15년 도입한 테스트 자동화 플랫폼은 수만 명이 하던 테스트 업무를 대체했지만, 해당 인력은 재교육으로 재배치.
- 액센추어는 연간 11억 달러를 직원 교육에 투자하고 있음.
 - 스킬 기반 인적자원 관리 시스템
 - 78만명의 직원들의 모든 스킬을 데이터베이스화하여
 - AI 알고리즘을 통해 효율적 인재 전환 가능하게 함.
 - 예시: 20시간 정도의 교육으로 클라우드 전문가로 전환 가능한 인재 발굴 등

※ Source : CES 2025 Keynote with Accenture Chair and CEO, Julie Sweet (CES, 2025)([LINK](#))

| 목차

이야기①

2025년 AI 트렌드

이야기②

물리적 AI(Physical AI)

이야기③

AI 에이전트(Agentic AI)

이야기④

온디바이스AI(OnDevice AI)

| 목차

- I. 물리적AI(Physical AI) 정의 및 의미
- II. 세계 모델(World Model; WM) 정의 및 현황
- III. PAI가 가져올 생태계 변화
- IV. PAI가 가져올 산업·사회·경제 변화
- V. 미중 AI 로봇 패권 전쟁
- VI. 시사점 정리

I. 물리적AI(Physical AI) 정의 및 의미

- PAI 정의의 출발
- PAI 정의 고도화
- NVIDIA의 PAI 정의

PAI는 AI가 비구조화된 실제 환경 속에서 자율적으로 행동, 적응, 회복하는 지능형 유기체들처럼 작업을 수행할 수 있는 물리적 시스템으로 첫 정의가 시작됨.

네이처지 PAI의 정의, 「자연의 생명체가 하는 복잡한 활동을 수행하는 AI임.」


- 네이처에 등재된 논문에 따르면「물리적 AI(Physical AI; PAI)는 지능형 유기체와 연관된 작업을 수행할 수 있는 물리적 시스템을 개발하는 이론과 실행을 의미」함.
 - 지능형 유기체와 연관된 작업을 수행할 수 있는 → 불규칙한 지형을 걸거나 달리는, 다양한 모양과 크기의 물체를 집고 조작하는, 예상치 못한 장애물을 피하는 등 「사람이나 동물처럼 똑똑한 생물체가 하는 복잡한 활동을 수행하는」으로 해석 가능함.
 - 물리적 시스템을 개발하는 이론과 실행 → ①이론은 어떻게 로봇이 작동해야 하는지에 대한 모델, ②실행은 그 이론을 실제로 만들어 내듯이 로봇을 조립하고, 프로그래밍하고 테스트 하는 것임.
 - ☞ 자연의 생명체에서 영감을 얻은 접근 방식임. 생물체가 비구조화된 실제 환경에서 자율적으로 행동, 제어기 적응 및 학습, 물리적 손상에 대한 회복력, 집단 시스템과의 통합 능력 등



※ Source : Skills for physical artificial intelligence(Dr. Aslan Miriyev, Prof. Mirko Kovac, 2020)([LINK](#))

디지털 속에서만 존재했던 기존 AI와 달리 PAI는 컴퓨터 과학뿐만 아니라 재료과학, 기계공학, 화학, 생물학 등 비구조화된 실제 환경을 이해하고 적응하는데 필요한 다학제적 접근이 필요함.

PAI는 다학제적 접근이 필요함.



학문 분야	핵심 역량	PAI에서의 역할
재료과학	폴리머 과학, 복합재료, 특성화, 가공	로봇의 물리적 구조와 특성 개발
기계공학	로보틱스, 메카트로닉스, 제조, 설계	움직임 및 제어 메커니즘 설계
컴퓨터 과학	프로그래밍, 기계학습, 데이터 과학, 네트워킹	로봇의 인지 및 의사 결정 시스템 개발
화학	화학합성, 분석화학, 유기화학, 생화학	새로운 로봇 재료 개발 및 분석
생물학	생리학, 조직공학, 생체역학, 식물학	생체모방 원리 및 구조 적용

※ Source : Skills for physical artificial intelligence(Dr. Aslan Miriyev, Prof. Mirko Kovac, 2020)([LINK](#))

자연 속 지능형 유기체에 영감을 얻어 손상 후에도 새로운 움직임을 보이거나 자가 치유하고 또 집단 속에서 공생하는 로봇들의 모습을 제안했음.

자가 적응하는 로봇



- 벌에서 영감을 받은 로봇 시스템은 재료, 구조, 자기 인식 및 구동에 관한 고려사항을 통합하여 자율적이고 다기능적인 로봇 시스템으로 진화함.
- 이러한 로봇 벌은 다양한 학문 분야의 지식을 활용하여 개발되며, 손상 후에도 새로운 움직임 전략을 발견할 수 있는 능력을 보여줌.

자가 복구하는 로봇



- 생합성 자가치유 재료는 손상 후 자체적으로 복구되어 로봇의 기능을 회복 가능함. 이러한 재료는 기계적 손상에 취약한 소프트 로봇에 특히 유용하며, 접근이 어렵거나 위험한 환경에서 작동하는 로봇임무 성공률을 높이고 유지 보수 비용 절감 간으함.

환경과 상호작용하는 로봇



- 집단 로봇 시스템은 여러 로봇이 협력하여 복잡한 구조물을 건설하는 방법을 보여줌.
- 농업, 해양 탐사, 우주 탐사, 재난 대응 등 다양한 분야에서 혁신적인 응용이 가능함.

※ Source : Skills for physical artificial intelligence(Dr. Aslan Miriyev, Prof. Mirko Kovac, 2020)([LINK](#))


2. PAI 정의 고도화

① 개요

ChatGPT 등 Gen AI 확대되었지만 물리적 세계와의 상호작용에 제약이 있음을 착안하여, 기존의 디지털AI 개념을 물리적 세계로 확장한 개념으로 PAI 정의 고도화됨. 자연과 유사한 로봇 시스템을 지능적으로 구동하는 것을 의미함.

물리적 AI(Physical AI) 개념의 고도화 및 구체화

- 현재 AI는 이미지 분류, 음성 인식 등에서 성과를 보이고 있지만, 물리적 세계와의 상호작용에는 제약이 있음.
- 2023년 발표된 논문에 따르면 「물리적 AI(Physical AI; PAI)는 기존의 디지털 AI 개념을 물리적 세계로 확장한 개념임. 자연과 유사한 로봇 시스템을 지능적으로 구동하는 것」을 의미함.
 - 기존의 디지털 AI 개념을 물리적 세계로 확장한 → 디지털 데이터 분석을 넘어서 재료과학, 기계공학, 컴퓨터과학, 화학, 생물학 등 다양한 분야의 통합 필요
 - 자연과 유사한 로봇 시스템을 지능적으로 구동 → 생물학적 시스템의 적응성과 자율성을 모방
- ☞ 지능과 물리적 형태의 결합이자, 디지털 데이터에서 벗어나 더 넓은 물리적 세계로 AI 영역을 확장하는 개념적 도약을 의미함.



※ Source : Physical Artificial Intelligence: The Concept Expansion of Next-Generation Artificial Intelligence (Yingbo LiYucong, 2021)([LINK](#)), Physical Artificial Intelligence (PAI) (Yingbo LiYucong, 2023)([LINK](#))

PAI는 자율적 의사결정과 행동을 독립적으로 하는지 군집으로 하는지에 따라서 통합형 PAI, 분산형 PAI로 구분하여 시스템을 구성할 수 있음.

PAI의 분류

	통합형 PAI(Integrated PAI)	분산형 PAI(Distributed PAI)
아키텍처	자체 완결형, 통합 시스템	별도 구성 요소로 이루어진 네트워크 시스템
처리 흐름	단일 유닛 내의 순차적 처리	여러 위치에 분산된 처리
구성 요소	센서→신호→특징 추출→예측→행동 결정	센서 클러스터+중앙처리허브+실행클러스터
데이터 처리	하나의 시스템에서 중앙 집중식	여러 노드에 분산됨.
입력 / 출력	물리적 세계에서 인식→물리적 세계에서 행동	물리적 세계에서 인식→물리적 세계에서 행동
확장성	단일 유닛 기능에 의해 제한됨	추가 센서 / 실행 노드로 높은 확장성
예시	온보드 센서 및 처리 기능을 갖춘 단일 자율 로봇	군집 로봇공학, 분산 센서가 있는 스마트 홈 시스템
구현	단순한 통합, 낮은 지연 시간(내부처리)	복잡한 통합, 높은 지연 시간(노드간 통신 필요)

※ Source : Physical Artificial Intelligence: The Concept Expansion of Next-Generation Artificial Intelligence (Yingbo LiYucong, 2021)([LINK](#)), Physical artificial intelligence (PAI) (Yingbo LiZhao, 2023)([LINK](#))


3. NVIDIA의 PAI 정의

① 개요

NVIDIA는 PAI를 실제 환경에서 작동하며 물리적 요소를 인식, 이해, 조작할 수 있는 인공지능으로 정의함. 현재 PAI를 위한 데이터 부족에 착안해서 데이터 합성-디지털 트윈-AI모델로 전개되는 디지털 트윈 프로세스를 따라 솔루션을 제안하고 있음.

PAI 정의

- NVIDIA가 정의하는 **PAI(물리적 AI)**는 로봇 공학, 자율 주행 차량, 비전 AI 등 **실제 환경에서 작동**하며 **물리적 요소를 인식, 이해, 조작할 수 있는** 인공지능 시스템을 포괄함.



PAI 구현 3요소(디지털 트윈 프로세스)

- 물리적 세계의 다양한 상황을 학습할 수 있는
- 실제 환경을 정확히 시뮬레이션 할 수 있는
- 물리적 법칙과 그 세계와의 복잡한 상호작용을 추론하고 결정할 수 있는

대규모 합성
데이터 생성



디지털 트윈
(시뮬레이션)



AI 모델
(이해·예측)

☞ 자동화는 특정 작업을 반복적으로 수행하는데 초점, 물리적 AI는 환경에 적응하고 학습하며 복잡한 결정 내리는데 초점.


※ Source : NVIDIA Omniverse Physical AI Operating System Expands to More Industries and Partners (NVIDIA, 2024), NVIDIA Expands Omniverse With Generative Physical AI (NVIDIA, 2024), NVIDIA Announces Major Release of Cosmos World Foundation Models and Physical AI Data Tools (NVIDIA, 2025)

- Researched, Written, and Created by DONG HYUNG SHIN(donghyung.shin@gmail.com)

② 물리적 AI 적용 플로우

NVIDIA는 ①코스모스 Transfer에서 실제 환경에서 수집하기 어려운 대규모 합성 데이터 생성, ②오픈USD 기반의 옴니버스로 시뮬레이션, ③코스모스 Predict/Reason으로 물리적 세계의 복잡한 상호 작용을 이해하고 예측, ④블루 프린터로 물리적 AI 시스템을 개발, 테스트, 배포 등 올 커버함.

NVIDIA 물리적 AI 적용 플로우



※ Source : NVIDIA Omniverse Physical AI Operating System Expands to More Industries and Partners (NVIDIA, 2024), NVIDIA Expands Omniverse With Generative Physical AI (NVIDIA, 2024), NVIDIA Announces Major Release of Cosmos World Foundation Models and Physical AI Data Tools (NVIDIA, 2025)

③ NVIDIA Physical AI 3대 핵심 구성 요소

NVIDIA는 코스모스 월드 파운데이션 모델, 물리적 AI 영역의 OS라 생각하는 비디오 기반 시뮬레이션 도구, 서비스 개발-배포를 통해 물리적 AI 서비스 확대를 도모하는 블루 프린트 등 물리적 AI 생태계 확대를 위해 필요한 도구들을 선보이고 있음.

코스모스(Cosmos) WFM

- 물리적 AI를 위한 기초 모델 시스템임. 마치 자연어 처리에서 GPT가 가져온 혁신과 유사한 패러다임 전환 예상
- ①코스모스 Transfer : 분할 맵, 깊이 맵, 라이다 스캔, 포즈 추정 맵, 궤적 맵 등 구조화된 비디오를 입력받아 제어 가능한 **사실적 비디오합성데이터 생성**
- ②코스모스 Predict : 텍스트, 이미지, 비디오 등 다양한 입력을 통해 가상 세계를 바탕으로 **움직임 궤적을 예측**
- ③코스모스 Reason : 시공간적 인식을 바탕으로 **물리적 세계의 상호 작용의 결과를 자연어로 예측**

옵니버스(Ominiverse)

- 세계의 물리적 데이터를 물리적 AI 영역에 연결하는 운영체제
- 옵니버스는 OpenUSD (Universal Scene Description) 프레임워크 기반으로 다양한 산업용 SW 도구와 데이터 형식간 상호운영성 문제 해결



블루 프린트와 개발자 도구

- 개발자들이 물리적 AI 시스템을 더 쉽게 구축할 수 있도록 개발툴킷 제공
- ①메가 : 옵니버스 Sensor RTX API 기반으로 산업용 공장이나 창고 디지털 트윈에서 개발 및 테스트
- ②자율주행차량(AV) 시뮬레이션 블루 프린트: 옵니버스 Sensor RTX API 기반 AV 개발자가 주행 데이터 재생 등으로 AV 테스트 및 검증에 위한 완전한 3D 센서 시뮬레이션 구현
- ③Apple Vision Pro: 옵니버스 공간 스트리밍 블루프린트는 Apple Vision Pro 로 몰입형 스트리밍을 위한 애플리케이션 개발 지원

※ Source : NVIDIA Omniverse Physical AI Operating System Expands to More Industries and Partners (NVIDIA, 2024), NVIDIA Expands Omniverse With Generative Physical AI (NVIDIA, 2024), NVIDIA Announces Major Release of Cosmos World Foundation Models and Physical AI Data Tools (NVIDIA, 2025)

NVIDIA는 물리적 AI가 제조업 및 물류 산업을 통해 확대될 것으로 예상하고 있음.

물리적 AI 적용 사례

산업	주요 적용 사례	핵심 가치 제안	주요 채택 기업
제조업	로봇 자동화, 품질 관리, 공정 최적화	생산성 향상, 비용 절감, 품질 개선	폭스콘, Pegatron, Schaeffler
물류/공급망	창고 자동화, 경로 최적화, 재고 관리	운영 효율성, 비용 절감, 처리량 증가	KION Group, Dematic, idealworks
자동차	자율주행 개발, 생산 라인 최적화	안전성 향상, 생산 효율성, 신규 서비스	현대자동차, 메르세데스-벤츠, Foretellix
전자 설계	칩 설계 자동화, 회로 시뮬레이션	설계 시간 단축, 성능 최적화	Cadence, Altair, Ansys
에너지/유틸리티	시설 최적화, 예측 유지보수	에너지 효율성, 가동 시간 증가	Schneider Electric, ETAP, Vertiv

※ Source : NVIDIA Omniverse Physical AI Operating System Expands to More Industries and Partners (NVIDIA, 2024), NVIDIA Expands Omniverse With Generative Physical AI (NVIDIA, 2024), NVIDIA Announces Major Release of Cosmos World Foundation Models and Physical AI Data Tools (NVIDIA, 2025)

| II. 세계 모델(World Model; WM) 정의 및 현황

- 2018년 첫 월드 모델
- 얀 르쿤의 WM
- 구글의 WM
- NVIDIA의 WM, COSMOS 모델

1. 2018년 첫 월드 모델

① 개요

월드 모델을 선보인 2018년 논문에서는 신호가 뇌로 도달하기 전에 본능적으로 움직여야 할 때도 있는 물리적 세상을 이해하고 대응하기 위해서 극복이 필요한 한계 및 구성요소(시각-기억-제어기)를 제시함.

물리적 세상 속에서 살고 있는 우리



- 타자는 100mph 속도로 날아오는 공을 치기 위해 ms 단위의 결정을 내려야 함. 이는 시각 신호가 뇌로 도달하는 시간 보다 짧음.
- 그럼에도 프로선수들은 본능적으로 공이 어디로 갈지 예측하고 적절한 타이밍에 스윙

※ Source: World Models (David Ha/Jurgen, 2018)([LINK](#))

물리적 세상 속 현실 한계

데이터 효율성 문제

- 기존 AI는 체스를 배우려면 수백만번 게임해야 하지만, 인간은 몇 판만 해도 기본 규칙 배우는 등 효율성 필요

고차원 데이터 저주 문제

- 데이터 크기나 특성이 많은 고차원 데이터는 학습에 어려워 압축해서 활용 필요

탐색과 이용의 균형 문제

- 새로운 탐색을 할지 이전과 그대로 할지, 월드 모델은 위험없이 다양한 시험 가능

실제 환경 내 훈련 비용 문제

- 로봇이나 자율주행차를 실제 환경에서 훈련시키는 데는 비용도 많이 들고 위험할 수 있음.

월드 모델 3가지 구성 요소

시각(V): AI의 눈, 세상을 압축하는 방법

- Vision 모델은 AI가 받아들이는 고차원 관측 데이터를 저차원 표현으로 압축하는 역할

기억(M): AI의 예측능력, 미래를 상상하기

- Memory 모델은 시간에 따른 변화를 모델링하고 미래 상태를 예측하는 역할

제어기(C): AI의 의사결정, 행동으로 옮기기

- Controller 모델은 V와 M 모델이 제공하는 정보를 바탕으로 행동을 결정하는 역할

2. 얀 르쿤의 WM

① 개요

얀 르쿤은 현재 AI가 학습효율성과 자율 주행의 한계 및 예상치 못한 상황 취약성 등 한계가 있다고 보고, 에이전트가 물리적 작동 방식에 대한 내부 표현을 구축하는 시스템인 월드 모델을 제안함. 주요 기능으로는 추론과 이를 바탕으로 한 예측이 핵심임.

현재 AI 한계

인간과 AI의 학습효율성 차이

- 인간은 20시간으로 운전을 배우지만, AI는 수백만 번의 시행 착오가 필요함.
- 인간은 세계에 대한 배경 지식과 내부 모델을 구축하는 능력에 기반함.

자율주행의 한계

- 인간 운전자는 몇시간의 경험만으로 대부분 도로 상황 적응이 가능함. 하지만 AI는 수백 만 번의 가상 환경 시뮬레이션과 전문가 데이터도 인간 수준 신뢰성 확보 못함.

예상치 못한 상황 취약성

- AI는 학습 데이터에 없는 상황에 적절히 대응 못함. 인간은 이전 경험하지 못한 상황도 추론과 적응을 통해 적절한 행동을 취할 수 있음.

월드 모델

월드 모델(World Model)은 에이전트가 물리적 세계 작동 방식에 대한 내부 표현을 구축하는 시스템임.

- 1943년 Kenneth Craik이 제안한 Mental Model을 기반한 개념으로 인간 심리학에서 유래함.

주요 기능

① 지각으로 얻지 못한 물리적 세계 상태에 대한 정보를 추정

② 자연적 진화 또는 행동 시퀀스에 따른 미래의 물리적 세계 상태 예측


추론



예측

얀 르쿤의 월드 모델은 지각, 월드 모델, 비용 모듈, 단기 기억, 행위자, 설정자 등 6개 요소가 서로 상호 작용을 하며 최적의 행동을 제안함.

Yann Lecun의 월드 모델



지각 (Perception)	센서에서 신호를 받아 세계의 현재 상태를 추정합니다.
월드 모델 (World Model)	지각에서 제공하지 않는 정보를 추정하고 미래 상태를 예측합니다.
비용 모듈 (Cost)	에이전트의 “불편함” 수준을 스칼라 값으로 측정함. 현재 상태를 나타내는 ①본질적 비용, 그 미래 값인 훈련 가능한 ②비평가
단기 기억 (Short-term Memory)	과거, 현재, 미래 세계 상태와 관련 비용 정보를 저장
행위자 (Actor)	행동 시퀀스를 제안하고 최적화
설정자 (Configurator)	모든 모듈을 조정하고 현재 작업에 맞게 구성

※ Source : A Path Towards Autonomous Machine Intelligence (LeCunYann, 2022)([LINK](#))

③ 월드 모델의 2가지로 구성된 지능형 시스템

지능형 시스템은 계산하지 않고 반응하는 ①직관적 대응형, 장기적인 결과를 고려한 더 나은 의사 결정을 하는 ②심사 숙고형 등 2가지로 구성됨.

Yann Lecun의 지능형 시스템 설계도

직관적 대응 : 빠르게 반응하는 모드

- 월드 모델이나 비용 계산을 사용하지 않는 순수 반응적 프로세스임.
 - 지각 : 물리적 세계 상태의 표현을 추출
 - 행위자 : 정책 구성 요소 상태를 기반으로 직접 행동 생성
- ☞ 계산 비용이 적고 빠른 반응이 가능하지만, 행동의 장기적 결과를 고려하지 않음.

심사 숙고 : 계획하고 추론하는 모드

- 월드 모델과 비용 모듈을 활용한 추론과 계획을 담당함.
 - 지각 : 물리적 세계 상태의 표현을 추출
 - 행동 제안 : 행위자가 초기 행동 시퀀스를 제안
 - 시뮬레이션 : 월드 모델이 제안한 행동에 따른 물리적 세계 변화를 예측
 - 평가 : 비용 모듈이 예측된 상태의 총 비용을 추정
 - 계획 : 행위자가 비용을 최소화하는 새로운 행동을 제안
- ☞ 계산 비용이 높지만, 장기적인 결과를 고려한 더 나은 의사 결정이 가능함. 또 새로운 상황이나 복잡한 문제에서 유용함.

구글은 AI 로봇에 필요한 3요소로 일반성, 상호작용성, 기민성을 정의하고, 추론에 집중한 Gemini Robotics-ER, 실행에 특화된 Gemini Robotics를 선보임. Gemini Robotics는 행동에 특화되어 있어 ER 버전 대비 Action 모델이 추가됨.

구글의 Physical AI

- 구글 Physical AI인 Gemini Robotics와 Gemini Robotics-ER은 Gemini 2.0의 물리적 세계 이해 능력을 기반으로 로봇 제어에 필요한 행동 예측 능력을 추가한 모델임.

똑똑한 로봇에게 필요한 3요소

- ① 일반성(GENERALITY)
 - 특정 작업을 넘어서 다양한 상황에 적응
- ② 상호작용성(INTERACTIVITY)
 - 사람들 및 주변 환경과 원활하게 상호작용하고 변화에 즉시 반응
- ③ 기민성(DEXTERITY)
 - 정밀한 움직임 구현

Gemini Robotics-ER vs. Gemini Robotics

구분	Gemini Robotics-ER	Gemini Robotics
핵심 기능	● 체화된 추론(Embodied Reasoning) 특화 ● 물리적 세계를 이해하고 해석하는 인지 엔진	● 실시간 로봇 액션 실행 특화 ● 체화된 추론을 기반으로 한 로봇 직접 제어 시스템(VLA(비전-언어-액션))
아키텍처 특성	● Gemini 2.0 기반 VLM(비전-언어 모델) ● 공간적 추론과 물리적 개념 이해에 최적화	● 클라우드 백본과 로컬 디코더의 이중 구조 ● 160ms 미만의 응답 시간, 50Hz 제어 주파수
제어 메커니즘	● 간접 제어 ● API 호출이나 코드 생성을 통한 로봇 명령 생성	● 직접 제어 ● 엔드 이펙터 위치와 그리퍼 동작을 직접 명령하는 연속적 액션 생성
실무 적용	● 로봇의 인지 프론트엔드 ● 장면 인식, 시공간 추론, 그래스프 포인트 예측, 궤적 계획	● 로봇의 실행 백엔드 ● 정밀한 양손 조작, 변형 가능 물체 핸들링, 실시간 환경 적응

※ Source : Gemini Robotics brings AI into the physical world (ParadaCarolina, 2025)(LINK)

4. NVIDIA의 WM, COSMOS 모델

① 개요

NVIDIA의 코스모스모델은 제한된 데이터 속에서 미래를 예측하는 월드 모델. 여기서의 제한된 요소를 최대한 극복하기 위해 대규모 비디오 큐레이터, 토크나이저 기술 및 유해 콘텐츠 차단 시스템을 포함함.

물리적 AI와 월드 모델

물리적 AI	- 물리적 AI는 센서와 액추에이터를 통해 실제 물리적 세계를 관찰하고 이와 상호작용하는 AI 시스템임. 예로써 자율주행차, 로봇 청소기, 휴머노이드 로봇 등 물리적 AI의 제약은 관찰과 행동이 담긴 대량의 데이터와 그 행동의 실제 결과치가 필요하다는 점임.
COSMOS WFM	- NVIDIA의 코스모스 WFM은 물리적 AI의 데이터 확장 문제 해결하기 위해 설계됨. - 코스모스 WFM의 핵심은 물리적 AI가 상호작용을 할 수 있는 “디지털 트윈”임. - 구성 요소로는 ①AI 자체의 디지털 트윈인 정책 모델, ②물리적 세계의 디지털 트윈인 월드 모델임.

COSMOS WFM(CWFM) 기술의 4대 핵심 요소

코스모스 WFM은 과거 관찰과 현재 입력에 기반해 미래 상태를 예측할 수 있음. 또 코스모스 WFM을 사용하면 가상 환경에서 다양한 시나리오를 시뮬레이션하고 안전하게 학습할 수 있음.	
대규모 비디오 큐레이터	①분할②필터링③주석④중복제거⑤패키징 단계로 진행. 20M 시간 분량의 원시 비디오 데이터 확보 및 1억개 고품질 비디오 클립 확보함.
토크나이저	고차원 원시 비디오 데이터를 비디오를 훨씬 더 효율적으로 압축하는 기술임.
월드 모델	사전 훈련된 AI 모델임. 복잡한 비디오 생성 문제를 더 쉬운 하위 문제로 분해하는 디퓨전 기반 WFM, 오토리그래시브 기반 WFM이 있음.
유해 콘텐츠 차단 시스템(안전장치)	유해한 프롬프트를 차단하는 사전 가드, 생성된 출력물 안전성 보장하는 가드레일 시스템이 있음.

※ Source : Cosmos World Foundation Model Platform for Physical AI (NVIDIA, 2025)([LINK](#))

| III. PAI가 가져올 생태계 변화

- PAI를 위한 가치 사슬
- PAI 환경 속 모델 차이

1. PAI를 위한 가치 사슬

① 개요

물리적 AI는 수집되는 센서 등 IoT 기반의 실제 물리적 환경에 대한 데이터 , 엣지 컴퓨팅 인프라, 월드 모델과 같은 새로운 AI 모델, 로봇 부분에서 차이가 있음.

물리적 AI를 위한 가치 사슬



2. PAI 환경 속 모델 차이

①개요

앞서 AI가 Physical AI로 전환되며 월드 모델이 최적화된 데이터센터가 향후 주요한 트렌드가 될 것으로 예상할 수 있음. 특히 그 차이는 LM은 텍스트 중심이나 WM은 이미지, 비디오, 라이다 등 실제 환경 데이터 중심으로 학습해야 하므로 최적화 대상이 다를 수 있음.

LM vs. WM

구분	Language Model (언어 모델)	World Model (세계 모델)
모델 핵심 차이점	텍스트 기반 패턴 학습 및 생성	현실 세계의 인과 관계, 물리 법칙, 상호작용 모사
주요 활용 분야	텍스트 생성, 번역, 질의응답, 요약	로봇 공학, 자율 주행, 시뮬레이션, 예측
학습 데이터	대규모 텍스트 코퍼스 (책, 기사, 웹사이트 등)	센서 데이터 (이미지, 비디오, 라이다 등), 시뮬레이션 환경, 실제 환경 데이터
모델 복잡도	상대적으로 낮음 (주로 Transformer 기반)	매우 높음 (다양한 모델 결합, 강화 학습 등)
계산 복잡도	높음 (대규모 텍스트 처리)	매우 높음 (실시간 물리 엔진 연산, 복잡한 추론)
데이터센터 최적화 방향	고속 텍스트 처리, 대규모 모델 학습	실시간 데이터 처리, 고성능 컴퓨팅, 저지연 네트워킹

| IV. PAI가 가져올 산업·사회·경제 변화

- 물리적AI, WM이 적용된 AI 로봇 시장
- AI 로봇 종류
- JST의 PAI와 로봇 발전 연구
- 리빙랩

1. 물리적AI, WM이 적용된 AI 로봇 시장

① 개요

물리적AI가 적용된 AI 로봇 시장은 citi에 따르면 `24년 3.54억대 규모에서 `50년 41.4억대로 성장할 것으로 예상되고 있음. 뿐만 아니라 시급에 따라 Payback Period도 충분히 짧아질 수 있도록 AI 로봇의 가격이 하락하고 있음.

AI 로봇 시장 추이(`24년 ~ `50년) & 휴머노이드 페이백 기간(주)

	2024	2025	2030	2035	2050	CAGR
Autonomous Vehicle	27	34	126	380	1858	17%
Domestic Cleaning Robot	286	326	541	793	1188	5%
Humanoids	0	0	1	13	648	61%
AGV & AMR	2	3	9	28	181	18%
Drone	37	40	54	73	149	5%
Caring Robot	0	1	6	18	71	20%
Commercial Cleaning Robot	1	2	6	14	25	11%
Food & Grocery Delivery Robot	0	0	4	11	19	19%
Food Service Robot	0	0	3	10	15	17%
Caring Overlap	0	0	(1)	(5)	(18)	
Total	354	405	749	1,337	4,136	10%

Hourly Wage (\$/h) \ Humanoid Price (\$)	15,000	20,000	25,000	30,000
7.25	21.6	28.7	35.9	43.1
16	9.8	13.0	16.3	19.5
28	5.6	7.4	9.3	11.2
41	3.8	5.1	6.4	7.6

- ☞ 시간당 임금 1만원이면 1.5만\$ 휴머노이드로 22주면 회수 가능함.
- ☞ 시간당 임금 5만원이면 1.5만\$ 휴머노이드로 3.8주면 회수 가능함.

※ Source : THE RISE OF AI ROBOTS:Physical AI is Coming for You (citi, 2024)([LINK](#))

MWC 2025에서 AI 로봇을 통한 자율화된 생산 시스템 구축에 대한 접근들이 나타나고 있음. 그 예로 AI와 로봇으로만 가동되는 알랏의 100% 자율 공장, 휴머노이드 로봇 디짓 등이 있음.

알랏의 100% 자율 공장

알랏	● 하메드 빈 살만 사우디 왕세자가 '24.02. 세운 공공 투자기금 회사로 사우디 아라비아를 첨단 기술과 전자 제품에 초점을 둔 '지속 가능한 기술 제조의 글로벌 허브'로 만들기 위해 세워진 기업 ● 2033년까지 1,000억\$ 투자 계획 공개하며, 공장 자동화를 넘어 제조업의 근본적 변화 목표
접근	● ①100% 청정에너지 기반 운영, ②완전 자율화된 생산 시스템, ③AI 기술의 전면적 적용 ☞ 생산 라인에 사람이 관여않고 AI·로봇 100%전담
예시	● 소프트뱅크 로보틱스 공장이 6개월이라는 짧은 시간 안에 최첨단 시설 구축됨. ○ 기존 공장 설립은 1~2년 소요 ○ 해당 공장은 디지털 트윈 기술을 활용한 사전 시뮬레이션과 모듈식 건설 방식으로 가능

애질리티 로보틱스의 디짓

배경	● 미국 물류 창고 분야에서만 약 4십만 개의 일자리 총원되지 않고 있는 현실
디짓	● 키 175cm, 무게 65kg으로 인간과 유사한 크기 ● 인간형 디자인: 인간을 위해 설계된 환경 최적화 ○ 좁은 복도, 계단, 문턱 등 인간 중심적 구조물을 탐색하는 데 휠 기반 로봇보다 우수함.
현황	● Agility Robotics는 미국 오리건주에 로보팸 (RoboFab)이라는 생산 시설 구축함.. ○ 모든 생산 라인이 가동되면 연간 약 1만대의 디짓 생산이 가능할 것으로 예상됨. ○ 디짓이 디짓을 생산하여 생산성을 향상시킬 전망


※ Source : Manufacturing and Production Summit: Unlocking the full potential of Smart Manufacturing beyond connectivity (GSMA, 2025)([LINK](#))

AI 로봇은 머리냐? 몸이냐? 관점에서 Embodied AI와 휴머노이드 로봇으로 구분 가능하며, 본질적으로 합쳐지는 범용 로봇으로 발전할 것임.

머리 관점 vs. 몸 관점

특징	Embodied AI	휴머노이드 로봇
정의	물리적인 형태를 갖추고 현실 세계와 상호작용하는 AI 시스템	인간의 신체적 특징과 유사한 외형을 갖고 인간처럼 움직이고 행동하는 로봇 시스템
외형	로봇, 드론, 자율주행차 등 다양한 형태	인간과 유사한 형태 (두 팔, 두 다리, 머리 등)
주요 기능	환경 인식, 움직임 제어, 의사 결정, 작업 수행 등	인간과의 상호작용, 감정 인식, 자연어 처리, 사회적 행동 등
강점	- 현실 세계에서 직접 경험하고 학습하여 빠른 적응 가능 - 다양한 형태로 구현 가능 - 특정 작업에 특화된 기능 수행	- 인간과 유사한 외형으로 친근감 및 사회적 수용성 증대 - 인간과의 상호작용에 최적화 - 복잡한 사회적 상황 이해 및 대응 가능
약점	- 복잡한 사회적 상황 이해 및 대응 어려움 - 인간과의 자연스러운 의사소통 어려움	- 기술적 복잡성 및 높은 개발 비용 - 윤리적 문제 발생 가능성 (인간과의 관계, 책임 소재 등)
활용 예시	자율주행 자동차, 드론, 산업용 로봇, 가정용 로봇, 의료 로봇 등	서비스 로봇 (호텔, 레스토랑, 상점 등), 교육용 로봇, 엔터테인먼트 로봇, 반력 로봇 등

Tesla 옵티머스



※ Source : [AI Report 2024-1] 2024년 AI 이슈를 용어와 함께 쉽게 이해하기 (백인수, 신동형, 2024)([LINK](#))

현재 산업용 특수 로봇이 전체 운용 중인 로봇의 90%로 대세이나, 협동 로봇, 이동형 로봇, 범용 로봇 등으로 진화해 나갈 것임.

로봇의 종류와 진화 방향

협동 로봇(코봇)
인간과 함께 일하는 로봇,
연간 설치의 약 10.5% 차지

이동형 로봇
AGV, 모바일 매니플레이터,
쿼드러페드, 휴머노이드 등
다양한 형태

산업용 로봇
전 세계 운용 중인 로봇의 90%
를 차지하는 현재의 주력

범용 로봇
어떤 환경에서도 작업 수행
가능한 로봇공학의 '성배'

※ Source :America Is Missing The New Labor Economy – Robotics Part 1 (Dylan PatelReyk, 2025)([LINK](#))

투자 분야에서는 휴머노이드가 주목받고 있으나, 실질적인 가치와 수익을 내고 있는 것은 특수 목적용 로봇이라는 현장 전문가들의 목소리가 있었음.

지금은 휴머노이드보다 특수목적 로봇

산업 현장에서는 아직은 휴머노이드 로봇의 실용성에 대한 회의적 시선이 있음.

- Lucid Bots의 창업자 Andrew는 로봇 설계의 가장 중요한 3요소는 ①강도, ②안정성, ③비용이라고 함. 그리고 회전 운동이 선형 운동보다 전력 효율이 높은 물리적 특성 고려시 인간의 형태 모방은 에너지 비효율적인 접근이라고 함.

	휴머노이드	특수목적용
유지보수비용	높음	낮음
작업효율성	제한적	높음
범용성	높음	제한적

특수 목적용 로봇이 가치를 내고 있는 예시



- DHL은 현재 전 세계적으로 7,500대 이상의 로봇을 운영중
- DHL은 인간을 대체하는 것이 아니라 보조하는 역할 중점
- DHL Sally Miller는 “창고에서 로봇이 다리로 걸을 필요 없으며, 오히려 배터리팩이 있는 안정적인 베이스가 더 효율적임.”



- Oshkosh는CES 2025에서 앱 등을 통해 주문형 쓰레기 및 재활용품 수거를 제공하는 자율형 쓰레기 수거로봇 혁신상 받음.
- 기능: 자동 쓰레기통 인식, 재활용품 오분류 감지, 위험물 자동 감지



- Siemens는 NVIDIA와의 파트너십으로 엣지 디바이스에 GPU를 탑재해 현장에서 실시간으로 의사결정 가능함.
- Siemens의 Rahul Garg는 “인간의 형태를 모방하는 것 자체가 비효율을 내재화하는 것임.”

모바일 로봇은 이동성을 갖췄으며 특정 환경 내에 최적화된 로봇이며, 범용 로봇은 다양한 환경에서 다양한 작업 수행이 가능한 로봇을 의미함.


AI 로봇 분류(모바일 vs. 범용)

	모바일 로봇				범용 로봇
	AGV(자율주행차량)	모바일 매니플레이터	쿼드러패드	휴머노이드	
특징	- 정의된 경로를 따라 이동 - 바퀴 기반 이동성 - 제한된 환경에서 운영	- 로봇 팔이 장착된 모바일 플랫폼 - 이동성과 조작 기능 결합 - 반구조화된 환경에서 작동	- 네 다리로 걷는 로봇 - 다양한 지형 탐색 가능 - 균형 제어 시스템	- 인간과 유사한 신체 구조 - 두다리로 걷는 기능 - 두 팔을 이용한 조작	- 다양한 환경에서 다양한 작업 수행 - 환경 변화에 적응 가능 - 새로운 작업 자율 학습 - 인간 수준의 다재다능함
주요 용도	- 창고 내 자재 이동 - 물류 센터 내 패키지 운반 - 공장 내 부품 운송	- 창고에서 물건 집기 - 제조 현장 지원 - 연구실 작업 - 의료 시설 지원	- 산업 현장 검사 - 건설 구역 모니터링 - 검색 및 구조 작업 - 형지 탐사	- 연구 및 개발 - 시연 / 교육 이벤트 - 인간 환경 서비스 - 엔터테인먼트	- 모든 산업 분야 - 가전 및 상업 서비스 - 인간 노동력 대체 - 위험 환경 작업

※ Source :America Is Missing The New Labor Economy – Robotics Part 1 (Dylan PatelReyk, 2025)([LINK](#))


테슬라의 옵티머스 Gen2는 더 자연스러운 움직임을 추구하고 있음.

TESLA Optimus Gen2



AI를 접목시킨다면, 완성도 보다는 대중화에 접근하는 방식이 더 맞을 것 같음.


대중성에 집착하는 Tesla Optimus



- Elon Musk는 휴머노이드의 가격은 차값의 반 정도가 되는 20K~25K\$가 적합하다고 봄.

Vs.

완성도에 집착하는 Boston Dynamics



- 군사용으로 시작해 완성도 측면에 더 집중하고 있는 Boston Dynamics

2.2. 자율 주행차① John Deere의 자율 주행 기술: 농부, 건설 노동 일손 부족 문제를 해결

John Deere는 「인력난 해소」라는 해답으로 「자율 주행 기술」을 선 보임. 카메라 16개, 엣지AI, 통합 관제가 2세대 자율주행의 핵심으로 기존 제품에 부착할 수 있는 레트로핏도 있음.

왜 자율 주행인가?

- 자원의 제약성에 대한 해답
 - CES 2025에서는 농업 및 건설업 “인력난 해소”를 위한 해답으로 「자율 주행 기술」을 선보임.
 - CES 2023에서는 “경작지 부족, 물 부족”에 대한 해답으로 「인공 지능」 선보였음.
- 인력난 해소를 위해 생산성 향상 필수
 - 인력난이 지속될 것인데, 그 배경에는 UN에서 2050년 인구가 현재 80억명이 100억명으로 증가함에 따라 식량과 주거 인프라의 폭발적 증가를 예상함.
 - 이를 위해 생산성의 혁신적 향상이 필수

자율주행을 적용한 제품들

- 2세대 자율주행 키트로 생산성 증대
 - 속도 2배, 작업 범위도 2배

제품	핵심 기술	주요 특징	해결 과제
9RX 대형 트랙터	16개 카메라 360도 시야	2배 빠른 속도, 2배 넓은 작업 범위	농업 인력난 (2.4M 일자리 부족)
5ML 과수원용 트랙터	라이다 센서 + 7개 카메라	전기/디젤 버전 동시 출시	야간 방재 작업 자동화
460 P-Tier 덤프트럭	GPS + 카메라 융합 시스템	92,000파운드 적재, 24시간 운영	건설현장 88% 인력난
전기 잔디깎이	4쌍의 스테레오 카메라	무소음, 무공해 운영	조경업체 86% 구인난

- 기존 장비에 자율주행 키트를 기존 제품에 부착할 수 있는 레트로핏 제공

2세대 자율 주행에 적용된 신제품

- Camera Array 기술(2개 → 16개)
 - 16개의 카메라가 다른 각도에서 같은 대상을 봐서 더 정확한 거리와 위치 확인 가능
- 엣지 케이스
 - 야간 작업 중 불빛에 이끌려 날아드는 나방 한 마리도 감지하여 약 18톤짜리 무게의 트랙터를 세울 수 있음. 이는 지속적으로 카메라의 데이터를 분석해서 학습해 가능함.
- 통합 관제를 통한 자동화 및 모니터링
 - 건설 현장 내에서 다른 차량과 도로를 공유하면서 실시간 조정 가능
 - 앱으로 장비 및 생산성 모니터링 가능

※ Source : John Deere Reveals New Autonomous Machines & Technology at CES 2025 (John Deere, 2025)([LINK](#)), Nothing Runs Like a Deere. Autonomously. | John Deere CES 2025 Press Conference (John Deere, 2025)([LINK](#))

자율 주행은 Lv0에서 Lv5까지 단계가 있으며, 현재 Lv4 자율 주행차량들은 특정 지역에서 볼 수 있음.

자율주행 기술의 단계 구분

단계	정의	주행 제어 주체	주행 중 변수 감지	차량 운행 주체
Lv0 (Hands On)	전통적 주행 (No Automation)	인간	인간	인간
Lv1 (Hands On)	부분 보조 주행 (Driver Assistance)	인간/ 시스템	인간	인간
Lv2 (Hands Off)	부분 주행 (Partial Automation)	시스템	인간	인간
Lv3 (Eyes Off)	조건부 자율주행 (Conditional Automation)	시스템	시스템	인간
Lv4 (Mind Off)	고도 자율 주행 (High Automation)	시스템	시스템	시스템
Lv5 (Driver Off)	완전 자율 주행 (Full Automation)	시스템	시스템	시스템


로보택시-지역/노선이 제한된 Lv4 고도
자율주행차



※ Source : Enter the Robotaxi Era(유진투자증권 , 2024)([LINK](#))

Teslas는 FSD, 즉 Full Self Driving 용어가 불러올 수 있는 논란을 차단하기 위해 Supervised FSD로 명칭을 정정했음. Lv3로 분류하는 것이 적당함.

Tesla의 Supervised FSD- 지리적 제한이 없는 Lv3 분류 적당




완전자율주행으로 분류되지 않는 Tesla

- Supervised FSD
 - 테슬라는 FSD(Full Self Driving) 용어가 불러올 수 있는 논란을 차단하기 위해 상용화 후 Supervised(운전자 감독하의) FSD로 명칭 정정함.
 - Supervised FSD는 도심 주행이 가능하나, 운전자의 주의 집중이 필요하기 때문에 Lv3 부분자율주행기술로 분류되어야 함.
- 지역적 제한 극복
 - 테슬라의 Supervised FSD(Lv3)는 Unsupervised FSD(Lv4)로 가기 위한 중간 단계임.
 - 현 Lv4의 로보택시들과 달리 지리적 제약없이 기술 구현 가능하다는 장점

PAI를 위해서는 인식-제어 및 다양한 환경에 적응할 수 있는 이해-대응 시스템이 구축되어야 함.

PAI의 신체 기능 획득을 위한 연구 개발 과제



① 차세대 AI 모델

- 이중 과정 이론(즉각적 대응형 & 심사숙고 이해형)
- 예측 코딩 이론(환경을 예측하여 대응 방안 또는 행동 제시)
- LLM을 넘어 VLA(Vision-Language-Action) / Embodied VLA 모델로

② AI- 신체 기능 시스템 융합 & 신체 기능 시스템

- 월드 모델 구축 및 활용 및 이를 활용한 로봇 제어 개발
- 모방 학습에 의한 조작 고도화
- 엣지 컴퓨팅 및 이를 지원하는 AI 칩셋


③ 사람에게 안전한 물리적 AI 시스템

- 안전 강화 학습(Safety Reinforcement Learning)
- 안전 → 안심을 위한 인문학적 연구

※ Source : PHYSICAL AI (フィジカルAI) とは？次世代のAI技術を徹底解説 (阿部代表のご挨拶, 2025) ([LINK](#))

JST에서는 PAI가 적용된 로봇이 P(성능), H(휴머노이드), A(적응)으로 각각 진화될 것으로 전망. 하지만 결국에는 범용 로봇으로 진화되지 않을까? 아니면 각각 진화될까? 궁금함.

PAI 적용 로봇의 발전 Type 분류



유형P(Performance): 물리적 세계 속 다양한 실제 작업 가능

- 어느 정도 제한된 환경 하에서 AI가 다양한 작업 수행 가능
- 작업에 따른 다양한 동작, 섬세한 동작, 고속 동작 추구
- 인간에게 할 수 없는 임무·동작 가능

유형H(Humanoid): 물리적 세계 속에서 인간과 협동·공진화

- 인간과 같은 지능·신체성·대화 능력 등을 갖춰 인간 대신 또는 인간과 협동으로 다양한 임무 수행 가능
- 인간 자체를 이해하기 위한 과학 연구 포함.

유형A(Adaptivenss): 물리적세계속 제한되지만 다양한환경에서 작업

- 임무의 종류는 어느 정도 제한되지만, 환경이나 조건에 따라서 다양성, 복잡성, 변동성, 불완전성이 있어도 견고히 임무 완수 필요

※ Source : PHYSICAL AI (フィジカルAI) とは？次世代のAI技術を徹底解説 (阿部代表のご挨拶, 2025) ([LINK](#))

4. 리빙랩

① TOYOTA, 로봇과 함께 공존하는 미래를 직조하는 ‘살아있는 실험실’의 탄생

’20년 하반기 폐쇄된 후지산 근처 도요타 자동차 공장 및 주변 매입으로 도요타 미래 기술 실험장인 리빙랩인 WOVEN CITY가 ’25년부터 Phase I 입주가 시작됨. 이처럼 World Model에서 시뮬레이션하지 않고 실제 테스트하는 경우도 있음.

TOYOTA WOVEN CITY



- 2025년부터 시작되는 Phase I 입주는 실제 생활 환경에서 기술 검증 접근
 - 구성원으로는 도요타 임직원 및 가족, 방문 과학자, 산업 파트너, 스타트업 기업가, 학계 인사 등과 같은 Inventor 그룹과 은퇴자와 거주자 등 Weaver임.(1단계는 위버 2천명)
- 미래 기술의 실험장인 리빙랩(LivingLab)
 - 자율주행차에서부터 날아다니는 자동차, AI와 로봇이 함께 하는 일상, 디지털 트윈 적용
 - 탄소 중립, 스마트홈, 스마트 시티, 미래 커뮤니티를 실험.

※ Source :CES 2025 Press Conference Akio Toyoda Remarks (TOYOTA, 2025)([LINK](#))

WOVEN CITY에서는 자율주행차에서부터 날아다니는 자동차, AI와 로봇이 함께 하는 일상, 디지털 트윈 적용, 탄소 중립, 스마트홈, 스마트 시티, 미래 커뮤니티를 실험하며 미래 모빌리티와 스마트시티와 사회의 CONCEPT 기획 및 개발을 진행할 예정임.

WOVEN CITY VIEW



※ Source :CES 2025 Press Conference Akio Toyoda Remarks (TOYOTA, 2025)([LINK](#))

| V. 미중 AI 로봇 패권 전쟁

- 로봇 시장 내 중국 입지

중국은 '23년 기준 전 세계 로봇 설치의 절반 이상을 차지 하는 등 로봇 산업 내 공고한 입지를 구축했음. 특히 DJI는 전 세계 상업용 드론 시장의 80%, 미국 소비자 시장의 90%를 점유 중임.

중국의 로봇 산업 지배 현황

51%

세계 로봇 설치

- '23년 기준 전 세계 로봇 설치의 절반 이상이 중국산으로 이루어짐.

50%

자국내 중국기업 점유율

- 중국 내 설치된 로봇 중 중국 기업 생산 비율 ('20년 30%에서 증가)

470대

로봇 밀도

- 근로자 1만 명당 로봇 수 ('15년 50대 미만에서 급증)

사례 DJI 드론

시장 지배력

- 전 세계 상업용 드론 시장의 80%, 미국 소비자 시장의 90% 점유함.

제조 생태계

- 심천 기반으로 부품 공급을 몇 시간 내에 받을 수 있는 이점

빠른 반복 개발

- GoPro보다 훨씬 빠른 개발 사이클로 기술적 우위 확보


규모의 경제

- 대량 생산으로 비용 절감과 품질 향상 동시 달성

※ GoPro는 드론 시장에 진입하려 노력했지만, 대부분의 제조가 중국, 말레이시아, 일본에 기반을 두고 있어 각 반복 개발에 몇 주 소요됨.

로봇 제조 비용 관점에서 볼 때, 부하 하중을 견딜 수 있는 로봇 팔 기준 미국이 중국에 비해 약 118.9% 더 비쌈. 이는 단순히 노동비 차이가 아닌 공급망과 산업 생태계 차이로 분석 됨.

로봇 제조 비용 : 미국 vs. 중국



- 표준 5Kg 페이로드(부하 하중을 견딜 수 있는) 로봇 팔 기준, 미국 (\$24,420)과 중국(\$11,155)간 118.9%의 비용 차이가 발생함.
- 이는 단순한 노동비 차이가 아닌 효율적 공급망과 산업 생태계의 차이임.

※ Source :America Is Missing The New Labor Economy – Robotics Part 1 (Dylan PatelReyk, 2025)([LINK](#))

한국과 일본은 인구 위기로 로봇 도입 가속화되고 있음. 중국은 중국 제조 2025 계획을 기반으로 국가의 지원을 통해 글로벌 입지를 강화하고 있음.

주요 로봇 강국의 전략 비교



- 인구 위기로 로봇 도입 가속화
- 한국은 세계 최고의 로봇 밀도(1만명당 1천대 이상)
- 일본은 핵심 부품 강세



- 유럽의 산업 중심이지만, KUKA가 중국에 인수되며 약화 중
- **Industrie 4.0** 추진에 근거해 진행 중



- ‘중국제조 2025’ 계획으로 급성장함.
- 대규모 정부 보조금, 수직 통합 산업 구조, R&D 집중 투자 중



- 기술 개발은 세계적 수준이나, 제조 기반 약화
- GDP 중 제조업 비중 10% 수준으로 감소

| 목차

이야기①

2025년 AI 트렌드

이야기②

물리적 AI(Physical AI)

이야기③

AI 에이전트(Agentic AI)

이야기④

온디바이스AI(OnDevice AI)

| 목차

- I. Agentic AI / AI Agent 정의
- II. 행동하는 AI인 에이전틱 AI 분류
- III. 기업별 AI 에이전트 전개 현황
- IV. 멀티 에이전트 시스템 진화
- V. DIGITAL & PHYSICAL AI Agent로 진화

1. Agentic AI / AI Agent 정의


① 개요

Agentic AI는 모델인 AI에 집중한 것이고, AI Agent는 실행하는 Agent에 집중한 것임. Agentic AI 또는 AI Agent에서 중요한 것은 생각에 그치지 않고 실제로 실행·행동 가능한 AI라는 점임.


Agentic AI / AI Agent

Actionable AI

자율 시스템



Agentic AI / AI Agent의 진화



챗봇은 미리 정의된 내용에서 답변하거나, 계획·추론하여 제안하는데 그치지만, AI Agent는 행동까지 가능함.

챗봇



AI Agent / Agentic AI




※ Source : [Tech Series] kt cloud AI 에이전트 #1 : 에이전트의 이해와 구성 요소(김지웅, 2025)([LINK](#))

③ 가능해진 하이퍼 개인화

하이퍼 개인화는 실시간으로 맥락을 인식해 “당신이 좋아할 것을 추천”하는 것이 아니라 “당신이 지금 필요한 것을 제공”한다는 점에서 차이가 있음. 물론 데이터 수집에 있어서 고객으로 신뢰 확보가 관건임.

전통적 개인화 vs. 하이퍼 개인화



구분	전통적 개인화	하이퍼 개인화
시간적 범위	과거 행동 데이터 기반	실시간 맥락 데이터 활용
서비스 제공 방식	"당신이 좋아할 것" 추천	"지금 필요한 것" 제공
기술적 기반	세분화 된 고객 그룹 분류	AI 기반 실시간 맥락 인식
데이터 접근법	빅데이터 수집 중심	목적에 맞는 올바른 데이터 선별
핵심 가치	관련성 있는 제안	실질적 문제 해결과 가치 제공

고객에게 데이터 통제력 보장 = 신뢰

- ①하이퍼 개인화가 지나칠 때 불쾌감 느낄 수 있음.(이 정보를 어떻게 알고 있는거지?), ②동의없는 데이터 수집의 불편함.(대화를 나눈 내용이 인스타그램 광고로 뜰 때 느낌), 이들을 관리하여 신뢰를 얻고 하이퍼 개인화를 하는것이 관건

※ Source :Hyper-Personalisation: Finding the Sweet Spot Between Value and Intrusion (GSMA, 2025)(LINK)

2. 행동하는 AI인 에이전틱 AI 분류

① 개요

에이전틱AI는 3가지 형태로 진화될 것임. 개인 일상을 지원하는 ①개인 에이전트, 특정 업무를 수행하는 ②업무용 에이전트, 기업·제품 웹사이트를 대체할 ③브랜드 에이전트임.

에이전틱 AI의 3가지 분류

에이전트 유형	주요 기능	적용 사례	발전 전망
개인 에이전트	개인 일상 업무 지원	여행 계획, 이메일 관리	모든 도구 일반화 필요로 발전에 시간 소요
업무용 에이전트	특정 업무 수행	코드 작성(Cursor), 계약서 검토(Harvey)	더 많은 전문 도메인으로 확장 예상
브랜드 에이전트	기업의 모든 고객 상호작용 담당	통신사 요금제 변경, 기술 지원	웹사이트/앱과 같은 핵심 디지털 정체성으로 발전

- 기업과 고객이 만나는 첫 Interface

※ Source : Keynote 10: Innovation In Action (GSMA, 2025)([LINK](#))


개인 에이전트는 사용자의 기억과 상황을 이해하고 사용자를 대리해 다른 사람들과 상호작용하는 디지털 페르소나(대리인)으로 까지 진화해 나갈 것임.

레벨	특징	예시
L1. 단순 단계 수행	미리 정의된 단계를 정확히 따라서 수행	“회의실 예약해줘” → “몇 시에 몇 명이 사용할 예정인가요?”
L2. 결정론적 작업 자동화	사용자 명령을 기반으로 정해진 작업 공간에서 자동 수행	“오늘 오후 2시 회의실 A를 4명 규모로 예약해줘!” → 시스템이 자동으로 예약 완료
L3. 전략적 작업 자동화	자율적으로 계획하고 피드백을 반영하여 작업 수행	“마케팅팀 주간회의 예약해줘” → 시스템이 과거 예약 패턴 분석하여 적절한 시간과 회의실 추천
L4. 기억 및 맥락 인식	사용자 기억과 상황을 이해하고 개인화된 서비스 제공	“지난번 회의처럼 준비해줘” → 시스템이 이전 회의의 장소, 참석자, 자료 등을 기억하고 동일하게 준비
L5. 디지털 페르소나	사용자를 대리해 다른 사람들과 상호작용하며 신뢰성과 안정성 확보	“다음 주 협력사 미팅을 내 대신 조율해줘” → 시스템이 사용자 스타일로 이메일 소통, 일정 조정, 참석자 확인까지 완료

※ Source : Levels of AI Agents: from Rules to Large Language Models (HuangYu, 2025)([LINK](#))


특정 업무를 자동화하는 업무용 AI Agent 등은 출시되어 있는 상황임.

maus.ai AI Agent 활용 예시



☞ B2B 공급 업체 발굴
([LINK](#))

☞ YC 기업 목록([LINK](#))



☞ 웹사이트SEO최적화([LINK](#))

☞ 계약검토([LINK](#))

※ Source : [maus ai](#)([LINK](#))

고객들의 경험은 그 접점에서 결정됨. 오프라인 접점에서 웹을 통한 온라인 접점으로 진화했다가 향후에는 AI Agent와 고객과 AI Agent를 둘러싼 증강 현실이 결정할 것임.

브랜드 에이전트로 진화



- 고객의 접점은 오프라인 매장과 브랜드 광고

※ Source :



- 고객의 접점은 온라인 쇼핑몰과 온라인 브랜드 광고와 웹사이트



- 고객의 접점은 AI Agent 그리고 AI Agent와 소통하는 증강현실

OpenAI는 더 쉬운 AI Agent 개발을 위해 Responses API와 Agent SDK를 출시해서 OpenAI 모델 기반의 AI Agent 확산을 꾀하고 있음.

OpenAI의 AI 에이전트

- AI에이전트는 사용자를 대신하여 독립적으로 작업을 수행 가능한 시스템임.

'25년까지 출시한 AI 에이전트

오퍼레이터

- 웹을 탐색하고 사용자를 위해 웹에서 다양한 작업을 수행 가능

딥리서치

- 사용자가 원하는 주제에 대해 상세한 보고서를 생성 가능함.

부족했던 점

- 다양한 목적과 사용처에 저 수준 API를 조합해야 하는 복잡성
- 개발 과정이 어렵고 시간이 많이 소요됨.
- 에이전트의 동작이 종종 불안정하고 예측 어려움.
- 비즈니스 로직과 에이전트 로직을 혼합하면 테스트 어려움.
- 프롬프트를 반복적으로 수정하는 번거로움.
- 복잡한 조율 로직을 직접 구현해야 하는

New(Responses API & Agent SDK)

웹
검색

- AI 모델이 인터넷의 정보에 접근할 수 있게 해 주는 기능

파일
검색

- 기업 내부 문서 검색 기능 강화
- '24년의 Assistant API 고도화
- 개발자들이 가상 머신이나 레거시 앱과 같은 컴퓨터 환경을 제어

CUA

- Operator 고도화
- 다중 에이전트 워크플로우를

Agent
SDK


- 조율하고 복잡한 애플리케이션을 구축하는 데 초점을 맞춘 오픈소스 프레임워크(Swarm 업그레이드)

※ Source :New tools for building agents (OpenAI, 2025)([LINK](#))


필요성

Google은 행동하는 AI인 AI Agent 확산을 위해서 Extension, Function, Data Store 관점에서 강화해 나갈 전망이다.

구글이 발표한 AI Agent 기술




AI Agent 3대 핵심 도구



※ Source :Agents (Julia WiesingerPatrick, 2024)([LINK](#))

구글은 AI Agent 성능 향상을 위해 Extension을 표준화하여 더 많은 정보 접근과 실제 행동 수행을 가능하게 하기 위해 멀티 에이전트 시스템을 지향하며 이를 위해 A2A 프로토콜을 제안함.

멀티 에이전트 시스템을 위한 표준 프로토콜 정의




- A2A(Agent to Agent) Protocol은 ‘클라이언트 에이전트’와 ‘리모트 에이전트’간 통신을 원활하게 함.
 - 클라이언트 에이전트: 작업을 구성하고 전달하는 역할
 - 원격 에이전트: 정확한 정보를 제공하거나 올바른 조치를 취하기 위해 해당 작업을 수행
- A2A Protocol의 3가지 핵심 기능
 - 에이전트 기능 발견: 에이전트가 자신의 기능을 다른 에이전트에게 알릴 수 있는 기능으로 최적 에이전트 식별에 활용
 - 클라이언트와 원격 에이전트간 작업 관리 및 조정(진행 상황 공유 및 조정 가능)
 - 사용자 경험 협상 프로세스: 단순 텍스트를 넘어 멀티 모달로 소통할 수 있게 하며, 결과적으로 사용자가 원하는 UI로 구현하는 프로세스

※ Source : Announcing the Agent2Agent Protocol (A2A) (Rao SurapaneniMiku, 2025)([LINK](#))

멀티 에이전트 시스템으로 진화를 위해 MCP가 제안 및 적용 및 활용되고 있음. MCP는 개발자가 데이터 소스와 AI 기반 도구 및 AI 기반 도구간 안전한 양방향 연결을 위한 개방형 표준임.

MCP 정의



- MCP(Model Context Protocol)
 - 개발자가 데이터 소스와 AI 기반 도구 간에 안전한 양방향 연결을 구축할 수 있도록 하는 개방형 표준
- MCP의 기본 아키텍처클라이언트-서버 모델.
 - 호스트 애플리케이션(Claude Desktop, IDE, AI도구 등)은 MCP클라이언트를 통해 여러 MCP서버에 연결
 - 각 MCP 서버는 특정 데이터 소스나 서비스에 대한 접근을 제공하며, 이를 통해 AI 모델이 더 넓은 범위의 정보에 접근할 수 있음.

→ 이를 통해 AI Agent가 소스나 서비스에 대한 접근성 확보 및 다양한 정보 확인 가능함. 또 AI Agent간 접근성 확보로 Multi AI Agent System 가능

※ Source : Introducing the Model Context Protocol (Anthropic, 2024)([LINK](#)), Model Context Protocol (MCP, 2025)([LINK](#)), MCP-Solver: Integrating Language Models with Constraint Programming Systems(SzeiderStefan, 2024)([LINK](#))

MCP는 API보다 더 가볍고 개별 서비스만 업데이트 가능한 효율적인 시스템으로 AI Agent 간 연결을 쉽게 확대시켜 멀티 에이전트 시스템을 확대시킬 것으로 예상됨.


MCP와 전통적 API간 비교

특성	전통적인 API	MCP
아키텍처	모놀리식 - 모든 기능이 하나의 거대한 시스템	마이크로서비스 - 독립적으로 작동하는 작은 서비스들의 모음
확장성	전체 시스템을 한 번에 확장 필요	필요한 개별 서비스만 확장 가능
프로토콜	주로 SOAP(무겁고 복잡함)	REST 또는 GraphQL(가볍고 효율적)
관리 효율성	수동 관리 - 개발자가 직접 보안, 라우팅 등 구현	API 게이트웨이로 자동화 - 보안, 라우팅, 모니터링 자동 처리
유연성	변경시 전체 애플리케이션 리빌드 필요	개별 서비스만 업데이트 가능
장애 격리	한 모듈 오류가 전체 시스템에 영향	서비스 간 격리로 장애 영향 최소화
배포	전체 시스템 재배포 필요	개별 서비스만 배포 가능


※ Source : Introducing the Model Context Protocol (Anthropic, 2024)([LINK](#)), Model Context Protocol (MCP, 2025)([LINK](#)), MCP-Solver: Integrating Language Models with Constraint Programming Systems(SzeiderStefan, 2024)([LINK](#))

Anthropic은 MCP를 제안한 만큼 Claude와 통합된 활용 가이드를 선보였음.

MCP 여부에 따른 AI Agent 차이



Claude와 MCP 통합



※ Source : Introducing the Model Context Protocol (Anthropic, 2024)([LINK](#)), Model Context Protocol (MCP, 2025)([LINK](#)), MCP-Solver: Integrating Language Models with Constraint Programming Systems(SzeiderStefan, 2024)([LINK](#))

MCP를 적용한 AI Agent는 더 깊이 이해하고 맥락에 맞는 인사이트·해결책을 제안할 수 있음.

MCP 연결 AI Agent의 활용 예

코드 개발 영역

- MCP를 통해 Git 저장소에 접근할 수 있는 MCP Client(Claude 등)는 개발자 코드베이스를 더 깊이 이해하고 맥락에 맞는 해결책을 제시할 수 있음.
- 이는 단순히 몇 줄의 재사용한 코드 조각을 기반으로 한 조언보다는 훨씬 유용함.

데이터 분석 영역

- MCP를 통해 데이터베이스나 데이터 파일에 접근할 수 있는 AI 에이전트가 실시간 데이터를 분석하고 인사이트를 제공할 수 있음.
- Postgres 데이터베이스에 연결된 MCP Client(Claude 등)는 SQL 쿼리를 생성하고 결과를 해석하여 비즈니스 질문에 답할 수 있음.

고객 지원 영역

- MCP를 통해 CRM 시스템과 지식 베이스에 접근할 수 있는 AI 에이전트가 고객 문의에 더 개인화되고 정확한 응답을 제공할 수 있음.
- 이는 단순히 일반적인 정보를 제공하는 것보다 고객 만족도 향상 가능함.

※ Source : Introducing the Model Context Protocol (Anthropic, 2024)([LINK](#)), Model Context Protocol (MCP, 2025)([LINK](#)), MCP-Solver: Integrating Language Models with Constraint Programming Systems(SzeiderStefan, 2024)([LINK](#))

MS는 멀티 에이전트 시스템이 가능해 짐에 따라 전체론적 AI 접근을 시도함.

MS의 AI 에이전트 접근

- AI 에이전트를 **센서 입력**을 바탕으로 물리적, 가상 또는 혼합 현실 환경에서 **맥락에 맞는 적절한 행동**을 자율적으로 실행하는 지능형 에이전트로 정의함.
- AI 에이전트가 기존 AI와 다른 점은 ①환경과의 상호작용 능력과 ②적응성임.
- 문제 제기 : AI 에이전트의 등장으로 전체론적 AI 접근이 필요함.
 - 1956년 다트머스 회의에서 최초 정의된 AI 원래 비전은 “환경으로 부터 정보를 수집, 그 안에서 효과적인 행동을 취할 수 있는 인공 생명체”였음.
 - 현재는 점차 세분화되어 각자의 전문 영역으로


AI 에이전트 핵심 기술 요소

학습	환경과 경험으로부터 배우기 ● 강화학습:보상에 기반해 상태와 행동 간의 최적 관계 학습 ● 보상학습:전문가의 시연 데이터를 활용하여 행동을 모방
기억	단기 및 장기 저장 정보 ● 단기기억:작업 수행 중 관찰된 행동과 인식 이력을 유지 ● 장기기억:환경·사용자 선호도에 적응 가능한 특정 작업 기억
행동	실제 및 가상 환경에서의 상호 작용 ● 에이전트의 행동은 환경 정의에 따라 가상 현실 환경에서의 상호작용이나 인간에게 말하기와 같은 행동도 포함 가능
인지	정보 처리와 의사결정의 오케스트레이션 ● Agency:피드백으로부터 학습, 목표를 추구하기 위한 결정, 상충되는 목표에 적응하는 능력 ● Embodiment:행동과 환경으로부터 피드백간의 관계 이해 및 활용하여 인식이나 제어에 영향을 미치는 능력


※ Source :Agent AI Towards a Holistic Intelligence (Microsoft, 2024)([LINK](#))

MS는 시각, 행동, 언어를 포함한 AI Agent Foundation Model을 제안하면서 물리적 AI를 포함하고 있음.

AI Agent Foundation Model



물리적 AI 구분



※ Source :Agent AI Towards a Holistic Intelligence (Microsoft, 2024)([LINK](#))

전체론적 접근으로 볼 때 결국 AI Agent는 물리적-디지털 현실이 결합된 증강 환경 속에서 다양한 AI Agent들이 협업하고 인간과도 협업하며 공존하도록 진화될 것으로 예상됨.

AI Agent의 미래



가상·증강·혼합 현실

- XR(AR/VR/MR) 환경에서 지능형 에이전트가 인간과 자연스럽게 상호작용하며 교육, 훈련, 엔터테인먼트 분야에 적용 가능함.

다중 에이전트 협업


- 여러 에이전트가 서로 학습하고 목표를 공유하며 복잡한 작업을 함께 수행하는 협력적 시스템으로 발전 예정임.

인간-AI 협업

- AI 에이전트는 인간의 의도를 이해하고, 적절한 자율성을 유지하며, 인간의 능력을 향상시키는 협력 파트너로 발전 전망임.

※ Source :Agent AI Towards a Holistic Intelligence (Microsoft, 2024)([LINK](#))

물리적-디지털 환경 속에서 로봇, AI Agent, 사람이 어울려 사는 환경을 전체론적 지능 즉 Holistic Intelligence라 할 수 있을 것임.



※ Source :Agent AI Towards a Holistic Intelligence (Microsoft, 2024)([LINK](#))

| 목차

이야기①

2025년 AI 트렌드

이야기②

물리적 AI(Physical AI)

이야기③

AI 에이전트(Agentic AI)

이야기④


온디바이스AI(OnDevice AI)

| 목차

- I. 온디바이스AI 정의
- II. EDGE AI 정의
- III. 온디바이스AI/엣지AI 미래

온디바이스AI는 클라우드 서버가 아닌 사용자의 기기 내에서 직접 AI 모델을 실행하고 처리할 수 있는 기술임.

클라우드 기반 AI vs. 온디바이스 AI




온디바이스AI 정의와 특징

- 온디바이스 AI는 클라우드 서버가 아닌 사용자의 기기 내에서 직접 AI 모델을 실행하고 처리할 수 있는 기술임.
- 데이터가 외부로 전송되지 않고 기기 자체에서 AI 추론이 이루어져 ① 프라이버시 보호(보안성), ② 실시간 응답 (저지연성), ③ 네트워크 독립성, ④ 에너지 효율성 등 장점 보유함.
- 스마트폰, PC, 자동차, IoT 기기 등 다양한 기기에서 AI 기능을 즉각적으로 활용할 수 있게 함.

※ Source : 온디바이스 추론의 혁신을 주도하는 AI 혁신 (1) (퀄컴 코리아, 2025)([LINK](#)), 온디바이스 추론의 혁신을 주도하는 AI 혁신 (2) (퀄컴 코리아, 2025)([LINK](#)), 온디바이스 추론의 혁신을 주도하는 AI 혁신 (3) (퀄컴 코리아, 2025)([LINK](#)), 손끝에서 만나는 인공지능 (삼성전자, 2025)([LINK](#))

EDGE AI는 네트워크의 끝단 또는 데이터가 생성되는 장치 및 그 가까운 곳에서 AI 알고리즘이 실행되는 기술임.

EDGE AI



EDGE AI 정의와 특징

- **EDGE AI**는 클라우드 서버가 아닌 데이터가 생성되는 장치 또는 그 가까운 곳에서 **AI** 알고리즘을 실행하는 기술임.
 - 스마트폰, **IoT** 센서, 카메라와 같은 엣지 디바이스에서 직접 데이터를 처리하고 분석하는 방식임.
 - 온디바이스**AI**는 네트워크와 독립될 수 있지만, **EDGE AI** 네트워크 가장 끝 단에 있어 완전히 독립될 수는 없음.
- **EDGE AI**는 ①지연 시간 최소화, ②데이터 프라이버시 강화, ③네트워크 대역폭 효율화, ④에너지 효율성 향상
- **EDGE AI** 발전은 하드웨어, 소프트웨어, **AI** 모델 최적화 및 네트워크와 같은 인프라 구조가 최적화가 되었기 때문임.

EDGE AI는 수많은 센서와 카메라가 설치된 도시, 또는 다양한 산업용 IoT 센서가 설치된 공장에서 활용될 수 있음.

스마트시티

도시 인프라에 설치된 수많은 센서와 카메라는 방대한 양의 데이터 생성, 이를 모두 클라우드로 전송하여 처리하는 것은 현실적으로 불가능함.

- 도로 교차로에 설치된 카메라는 **Edge AI**를 통해 차량과 보행자 흐름을 실시간으로 분석하여 신호등 타이밍을 최적화함.
- **Edge AI** 기반 비디오 분석이 범죄 예방과 긴급 상황 대응에 활용됨. 중국 선전시는 안전 모니터링 시스템으로 범죄 발생률 **27%** 감소 시킴.
- 대기질, 소음, 기상 조건을 모니터링하는 센서 네트워크로 이상치 감지함. 싱가포르의 스마트 네이션 이니셔티브는 오염원 실시간 추적 대응함.
- 토론토의 스마트 빌딩프로젝트는 **Edge AI** 기반 에너지 관리 시스템을 통해 건물 에너지 소비를 **17%** 감소 시킴.

스마트 제조

산업용 IoT 센서의 급증과 실시간 모니터링 및 분석 요구가 **Edge AI** 도입을 가속화하고 있음.

- 예측 유지보수
 - 기계 장비에 설치된 센서가 수집한 진동, 온도, 소음 데이터를 **Edge AI**가 실시간으로 분석하여 장비 고장을 예측함.
- 품질 관리
 - 생산 라인에 설치된 카메라와 센서가 수집한 데이터를 **Edge AI**가 분석하여 제품 결함을 실시간으로 감지함.
- 자산 최적화
 - **Edge AI**는 생산 장비의 성능을 실시간으로 모니터링하고 분석하여 에너지 사용, 생산 속도, 자원 활용을 최적화함.
- 로보틱스 & 자동화
 - 로봇에 내장된 **Edge AI**는 환경 변화에 실시간으로 적응하고, 복잡한 작업을 자율적으로 수행함.

※ Source : Edge AI: A Taxonomy, Systematic Review and Future Directions (Sukhpal Singh Gill/Muhammed, 2024)([LINK](#))

3. 온디바이스AI/엣지AI 미래

① 개인용 슈퍼 컴퓨터

Project DIGITS는 \$3,000대로 예상하고 있는 개인용 슈퍼 컴퓨터 프로젝트임. PC가 세상을 변화시켰듯이 누구나 슈퍼 컴퓨터를 갖게 된다면 세상이 어떻게 변화될 것인가?

Project DIGITS



※ Source : NVIDIA CEO Jensen Huang Keynote at CES 2025 (Youtube, 2025)([LINK](#)), NVIDIA and Partners Launch Agentic AI Blueprints to Automate Work for Every Enterprise (BoitanoJustin, 2025)([LINK](#)), NVIDIA Announces Isaac GR00T Blueprint to Accelerate Humanoid Robotics Development (Huangpencer, 2025)([LINK](#)), NVIDIA CES 2025 Keynote Live Coverage(SmithRyan, 2025)([LINK](#))

② 온디바이스AI/엣지AI가 구동되는 반도체

몇 년 전만하더라도 온디바이스AI/엣지AI는 NPU 중심이었으나, 이제 고성능과 보편성을 지원하는 GPU도 PC로부터 시작되고 있음. 향후 온디바이스AI/엣지AI는 어떤 반도체 위에서 구동될까요?

과거 경험

피쳐폰



- MP3 플레이어칩, DMB칩 등 다양한 멀티미디어 칩들이 존재했음.




스마트폰



- 다양한 멀티미디어 칩셋이 Application Processor에 흡수 통합됨.


분리 vs. 통합




※ Source :

온디바이스AI/엣지AI는 궁극적으로는 클라우드 AI 또는 EDGE AI-HUB으로 하이브리드 형태로 구동될 것으로 예상됨.

하이브리드식(파편화 관리)



흠(중간에 관리)



※ Source :

감사합니다.

- 해당 자료는 지속 업데이트하고 공개할 예정입니다.
- 사례로 넣고 싶으신 기업 또는 협업하고픈 기업·기관 환영합니다.
- 보고서 또는 책 출간 및 강연 관련 문의는 언제든지 연락 주세요.

신동형

010-2202-8761

donghyung.shin@gmail.com

“편안하게 활용하시고 많이 공유해 주세요. 단, 인용시 반드시 출처를 밝혀 주십시오”