

AWS TechCamp Online

Amazon Bedrock으로 RAG 및 GraphRAG 완벽 마스터하기

Jiyun Park(박지윤)

Solutions Architect
Amazon Web Services



Agenda

- RAG란?
- ConventionalRAG와 Amazon OpenSearch Service
- GraphRAG와 Amazon Neptune
- Amazon Bedrock Knowledge Base 및 RAG 구현하기

AWS TechCamp

AWS TechCamp 는 AWS 기술을 실시간 실습을 통하여 빠르고 쉽게 향상시킬 수 있는 프로그램입니다. 참가자들은 실전 경험을 쌓고 AWS 기술을 직접 배우고 적용해볼 수 있습니다. 실시간 이론+실습 세션을 통하여 AWS의 다양한 서비스와 기능을 테마별, 인더스트리별로 경험할 수 있습니다.

[온라인] 분기별 3일 과정 세션

분기별 3일 과정의 세션 AWS TechCamp 온라인 세션의 경우 3월, 6월, 9월, 11월 총 4회 제공합니다. 세션은 3일 동안 진행되며 클라우드 클라우드 서비스가 생소한 분들을 위한 기초 과정 (레벨 100), 클라우드 기본 서비스 교육이 필요하신 분들을 위한 기본 과정 (레벨 200) 으로 이루어져 있습니다.

[오프라인] 인더스트리 세션

TechCamp 오프라인 세션은 특정 인더스트리에 대한 주제로 초청 고객 대상 집중 세션으로 구성된 기본/심화 과정 (레벨 200-300)이 진행됩니다.

관련 문의는 aws-korea-event@amazon.com으로 연락 주시기 바랍니다.

감사 메일 & 참석 증명서

- AWS TechCamp 온라인 세션에 참석해 주신 분들께 행사 종료 후 1개월 내 감사메일과 참석 증명서가 순차 발송됩니다.
- 등록 진행 후 참석하지 않으실 경우 별도 메일 및 증명서는 발급되지 않습니다.

감사 메일 예시

**AWS TechCamp 온라인 세미나에
참석해 주셔서 감사합니다.**

AWS TechCamp 온라인 세미나에 참석하고 피드백을 공유주셔서
감사합니다. 세미나 자료는 아래 링크를 통해 확인하실 수 있습니다.

[자료 확인하기](#)

참석 증명서 예시

참석 증명서

AWS TechCamp 온라인 세미나에 참석해 주셔서 감사합니다.


홍길동

2025년 3월 25일 - 3월 27일




RAG란?

Generative AI Innovations at Amazon



Rufus
쇼핑 어시스턴트




Amazon.com
고객 리뷰



**Amazon
Pharmacy**
더 빠른 처방과 지원

전통적인 파인 튜닝



Customize models with simple configuration

Epochs, batch size, learning rate, warmup steps

Hyperparameters
Info

Epochs
The total number of iterations of all the training data in one cycle for training the model.

Batch size
The number of samples processed before the model is updated.

Learning rate
The step size for incrementing parameters at each iteration.

Learning rate warmup steps
Number of iterations over which learning rate is gradually increased to the initial rate specified.


- ✓ Easy
- ✓ Secure
- ✓ Private

Simplified hyper params update


Data encrypted with customer managed keys

Access to Amazon S3 bucket via AWS PrivateLink


RAG(Retrieval Augmented Generation)




RAG(Retrieval Augmented Generation)



비슷한 의미의 텍스트 검색



임베딩



Conventional RAG와 Amazon OpenSearch Service

Vector 거리 측정

오렌지 주스 [10, 20, 10, ...]

테니스화 [1,999,-111,...]

물 200ml [-88, 24, 9,...]

검색어와 상품들 간의
거리 계산

가장 가까운 n개를
고름



새콤한 오렌지
음료수 250ml

[10, 19, 9, ...]

Vector 거리 측정

오렌지 주스 [10, 20, 10, ...]

테니스화 [1,999,-111,...]

물 200ml [-88, 24, 9,...]

거리 측정 방법

검색어와 상품들 간의
거리 계산

알고리즘

가장 가까운 n개를
고름




새콤한 오렌지
음료수 250ml

[10, 19, 9, ...]

Vector 거리 측정 방법



spaceType	Distance Function (d)	OpenSearch Score
l1 (맨하탄 거리)	$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n x_i - y_i $	$score = \frac{1}{1 + d}$
l2 (유클리드 거리)	$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$	$score = \frac{1}{1 + d}$
linf (체비쇼프, 체스보드 거리)	$d(\mathbf{x}, \mathbf{y}) = \max(x_i - y_i)$	$score = \frac{1}{1 + d}$
cosinesimil (Cosine 유사도)	$d(\mathbf{x}, \mathbf{y}) = 1 - \cos\theta = 1 - \frac{\mathbf{x} \cdot \mathbf{y}}{\ \mathbf{x}\ \cdot \ \mathbf{y}\ }$ $= 1 - \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \cdot \sqrt{\sum_{i=1}^n y_i^2}}$ where $\ \mathbf{x}\$ and $\ \mathbf{y}\$ represent the norms of vectors $\mathbf{x}$ and $\mathbf{y}$ respectively.	nmslib and faiss: $score = \frac{1}{1 + d}$ Lucene: $score = \frac{2 - d}{2}$
innerproduct (supported for Lucene in OpenSearch version 2.13 and later) (내적)	Lucene: $d(\mathbf{x}, \mathbf{y}) = \mathbf{x} \cdot \mathbf{y} = \sum_{i=1}^n x_i y_i$	If $d \geq 0$, $score = \frac{1}{1 + d}$ If $d < 0$, $score = -d + 1$ Lucene: If $d > 0$, $score = d + 1$ If $d \leq 0$ $score = \frac{1}{1 + (-1 \cdot d)}$



2	2	2	2	2	3
2	1	1	1	2	3
2	1	0	1	2	3
2	1	1	1	2	3
2	2	2	2	2	3
3	3	3	3	3	3

Cosine distance


Euclidean distance



<https://opensearch.org/docs/2.11/search-plugins/knn/knn-score-script/>


Vector 거리 검색 방법

kNN (k-Nearest Neighbors) Algorithm




벡터 검색의 제약조건

- 리소스
- 성능
- 확장성



Vector 거리 검색 방법

ANN(Approximate Nearest Neighbor) Algorithm



- 인덱스를 더 효율적으로 재구성
- 검색 가능한 벡터의 차원을 줄여 속도를 높임
- 정확도를 희생하고 검색 속도가 크게 향상
- 수십만 개 이상 벡터 검색 시 사용

Vector 거리 검색 방법

ANN(Approximate Nearest Neighbor) Algorithm

알고리즘 (method.name)

Graph-based (HNSW)

Cluster-based (IVF)

Hash-based(locality-sensitive hashing)

Tree-based(ANNOY)

라이브러리 (method.engine)

nmslib

HNSW

Lucene

HNSW

faiss

HNSW, IVF

Vector 거리 검색 방법

ANN(Approximate Nearest Neighbor) Algorithm

알고리즘 (method.name)

Graph-based (HNSW)

Cluster-based (IVF)

Hash-based(locality-sensitive hashing)

Tree-based(ANNOY)

라이브러리 (method.engine)

nmslib

HNSW

Lucene


HNSW

faiss

HNSW, IVF

Vector 거리 검색 방법

ANN(Approximate Nearest Neighbor) Algorithm





>100M
런칭 이후 다운로드 수

Top 4 검색 엔진
DB-Engines 랭크

Amazon OpenSearch Service

Amazon OpenSearch Service는 운영 데이터의 실시간 검색, 모니터링 및 분석을 안전하게 제공합니다.



관리형: 많은 유즈케이스가 있는 오픈 소스 솔루션을 관리형으로 사용하여 운영 우수성 확보



보안성: 견고한 네트워크 아키텍처와 내장된 인증 도구로 데이터를 감시하고, 안전하게 보호



가시성: 머신러닝 기반 탐지 및 경보 체계, 시각화 기능을 통해 잠재적 위협을 감지하고 체계적으로 대응



비용 최적화: 시간과 자원 사용 최적화

OpenSearch의 검색 방법

Semantic Search

- Vector Search를 활용한 검색 방법
- 문장의 의미나 사용자의 의도를 파악한 검색 결과 반환
- 자연어 질문에 적절한 답변 제공 가능

Lexical Search

- 확률 랭킹 프레임워크(BM25)를 사용한 키워드 검색 방법
- Match Query(일반적인 키워드 검색)
- Term Query(정확한 단어 검색)
- Multi Match Query(여러 필드를 검색)

OpenSearch의 Hybrid Search

Lexical Search

- 확률 랭킹 프레임워크(BM25)를 사용한 키워드 검색 방법
- Match Query(일반적인 키워드 검색)
- Term Query(정확한 단어 검색)
- Multi Match Query(여러 필드를 검색)

Semantic Search

- Vector Search를 활용한 검색 방법
- 문장의 의미나 사용자의 의도를 파악한 검색 결과 반환
- 자연어 질문에도 적절한 답변 제공 가능



Hybrid Search

Hybrid Search

데이터 인덱싱

```
PUT /products-shirts
{
  "settings": {
    "index": {
      "knn": true
    }
  },
  "mappings": {
    "properties": {
      "item_vector": {
        "type": "knn_vector",
        "dimension": 3,
        "method": {
          "name": "hnsw",
          "space_type": "l2",
          "engine": "faiss"
        }
      }
    }
  }
}
```

knn: 벡터 검색 기능을 켜는 설정

method.name: 사용할 알고리즘 이름

method.space_type: 거리 계산 방식

method.engine: 검색 엔진

Hybrid Search

🔗 AWS Generative AI/Machine Learning Samples - Korea

Contribution Welcome LICENSE MIT hits 11 / 1975

디렉토리 구조

AWS AIML 코드 및 워크샵 예제가 있습니다. 본 리포지토리의 대표 코드를 아래 3가지 카테고리를 보시면 됩니다. 각 디렉토리별 Readme 파일을 참고하십시오.

- [Generative AI](#) : Generative AI와 관련된 예제 및 관련 서비스 응용사례
 - [AWS Generative AI Applications](#)
 - [AWS Generative AI Model Deployment \(Inference\)](#)
 - [AWS Generative AI Model Fine-tuning \(Training\)](#)
- [SageMaker AI](#) : End-to-end 머신러닝/딥러닝 플랫폼 SageMaker 활용 예제
 - [SageMaker AI 101 - SageMaker 훈련 시작하기 \(입문\)](#)
 - [SageMaker HyperPod - 모델 훈련](#)
- [AWS Neuron](#) : AWS Neuron (Inferentia, Inferentia2, Tranium)의 관련된 예제 및 활용

License

This library is licensed under the Apache 2.0 License. For more details, please take a look at the LICENSE file.

<https://github.com/aws-samples/aws-ai-ml-workshop-kr/>



GraphRAG와 Amazon Neptune

그래프는 '관계'를 본다

GraphRAG

데이터

GraphRAG

복잡한 관계성을 컨텍스트 손실 없이 구현하기 어려움

데이터

GraphRAG

복잡한 관계성을 컨텍스트 손실 없이 구현하기 어려움

데이터



미묘한 논리적 관계
근거 기반 검색


GraphRAG

복잡한 관계성을 컨텍스트 손실 없이 구현하기 어려움

데이터



Graph 활용



데이터를 그래프로 모델링
RAG application — 인간 사고 체계

GraphRAG


복잡한 관계성을 컨텍스트 손실 없이 구현하기 어려움

데이터




Graph 활용

관계 기반, 추론 기반, 근거 기반의
검색이 가능해짐




데이터를 그래프로 모델링
RAG application — 인간 사고 체계

Knowledge Graph 및 주요 개념




Knowledge Graph 및 주요 개념



Node(개체) 엔티티

Properties(속성)

Knowledge Graph 및 주요 개념



Node(개체) 엔티티

Properties(속성)

```
g.addV('Person')
  .property('id', 'steve_jobs')
  .property('name', 'Steve Jobs')
  .property('birth_year', 1955)
```

Node: Person

```
g.addV('Company')
  .property('id', 'apple_inc')
  .property('name', 'Apple Inc.')
  .property('founded_year', 1976)
```


Node: Company

```
g.V('steve_jobs')
  .addE('founded')
  .to(g.V('apple_inc'))
  .property('year', 1976)
  .property('role', 'Co-founder')
```

Edge



Knowledge Graph 및 주요 개념



✓ Graph RAG에서 효과적인 질문

1. Steve Jobs가 설립한 회사가 위치한 도시에서 열린 이벤트에서 공개된 제품은 무엇인가요?
2. 2007년에 Steve Jobs가 소개한 제품 중, Apple과 직접 관련된 것은 무엇인가요?



Amazon Neptune

뛰어난 확장성과 가용성을
제공하는 고성능의 그래프 분석
서버리스 데이터베이스

뛰어난 확장성과 가용성을 위해 설계된
서버리스 그래프 데이터베이스


다양한 종류의 그래프 프레임워크 지원

표준화된 그래프 언어로 쿼리 작성 가능

벡터 및 그래프 알고리즘 지원

보안, 프라이버시 및 데이터 거버넌스

Amazon Bedrock Knowledge Base로 RAG 구현하기



Amazon Bedrock Knowledge Base

사용자의 개인 데이터 소스로부터 맥락 정보를 제공하여, 검색 증강 생성(RAG)을 통해 더 관련성 높고, 정확하며, 맞춤형된 응답을 제공할 수 있도록 대형 모델(FMs)과 에이전트를 지원합니다.



End-to-end RAG 워크플로우를 위한 완전 관리형 서비스



FM과 에이전트를 데이터 소스에 안전하게 연결




관련 데이터를 쉽게 검색하고 프롬프트를 보강




출처(데이터 소스) 정보 제공


RAG(Retrieval Augmented Generation)



RAG(Retrieval Augmented Generation)



RAG(Retrieval Augmented Generation)




GraphRAG vs Vector RAG 언제 사용해야 할까요?



**Conventional RAG 사용을
고려해야 하는 경우**

질문에 대한 빠른 문서 검색 & 응답
생성이 필요한 경우



**GraphRAG 사용을
고려해야 하는 경우**

복잡한 관계를 맺고 있을 때의
데이터 검색 혹은 추론이 필요한 경우

Thank you!

Jiyun Park

jiyunp@amazon.com

